

Sviluppo di algoritmi di machine learning per l'identificazione della fibrillazione atriale a partire da serie temporali di variabilità cardiaca

Corso di laurea in Informatica per la Comunicazione Digitale

Biagio Chiarandà (959914)

Relatore: Dott. Massimo Walter Rivolta

Correlatori: Dott. Md Moklesur Rahman e Prof. Roberto Sassi



UNIVERSITÀ DEGLI STUDI DI MILANO



Contesto iniziale

Il progetto, svolto presso il BiSP Lab dell'Università degli Studi di Milano, mira a sviluppare algoritmi di Machine Learning per l'identificazione automatica della fibrillazione atriale da segnali ECG, in collaborazione con il Dott. Massimo Walter Rivolta e Dott. Md Moklesur Rahman.

L'integrazione tra tecniche di elaborazione del segnale e Machine Learning rappresenta un approccio promettente per migliorare la diagnosi automatica e non invasiva di patologie cardiache.

Obiettivo del lavoro

L'obiettivo principale del lavoro è stato lo **sviluppo e il confronto di algoritmi di Machine Learning** in grado di identificare automaticamente casi di fibrillazione atriale.

Per raggiungere questo scopo, sono stati svolti i seguenti passaggi:

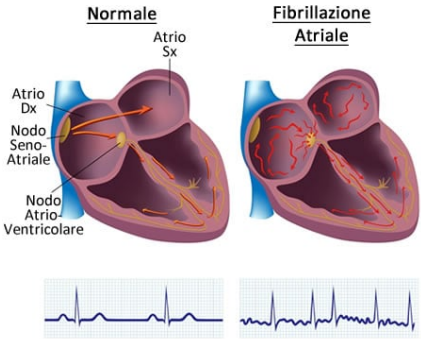
- **Preprocessing** per migliorare la qualità dei dati
- **Segmentazione** dei segnali in finestre temporali di 10 secondi
- **Estrazione di feature** basate su HRV e PRSA
- **Addestramento e ottimizzazione** di diversi modelli di ML
- **Validazione e confronto** su dataset pubblici (PhysioNet, MIT-BIH)

Cos’è la Fibrillazione Atriale?

La fibrillazione atriale (AF) è la più comune aritmia cardiaca e si verifica quando gli atri del cuore battono in modo irregolare e disorganizzato, invece di contrarsi normalmente.

La fibrillazione atriale viene diagnosticata tramite elettrocardiogramma, che mostra:

- **Assenza dell’onda P**
- **Intervalli RR irregolari**





Dataset utilizzati

Caratteristica	MIT-BIH AFDB	PhysioNet 2017
Fonte	Beth Israel Deaconess Medical Center	Vari istituti (PhysioNet)
Numero di registrazioni	24	Oltre 8.500
Durata dei segnali	10 ore ciascuno	Variabile (da 9 a 60s)
Derivazioni ECG	2	1
Frequenza di campionamento	250 Hz	300 Hz
Risoluzione	12-bit	16-bit
Categorie di ritmo	AF, AFL, J, N	AF, Noisy, Normal, Other Rhythms

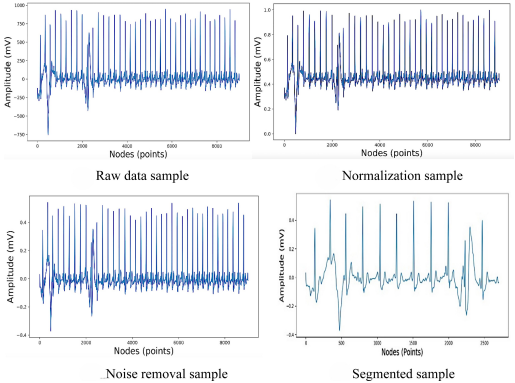
Esperimenti

1. Addestramento e validazione del modello su ampio dataset bilanciato (PhysioNet 2017), segmentato in finestre regolari di 10 secondi e suddivisio in training e test assicurando la separazionetra pazienti.
2. Addestramento e validazione su un sottoinsieme casuale del secondo dataset (MIT-BIH AFDB), mantenendo anche in questo caso la separazione tra pazienti.
3. Validazione incrociata tra dataset, con addestramento su segmenti del PhysioNet 2017 e test sui dati del MIT-BIH.

Preprocessing

Prima dell'estrazione delle feature, i segnali sono stati sottoposti a una fase di pre-processamento che ha incluso:

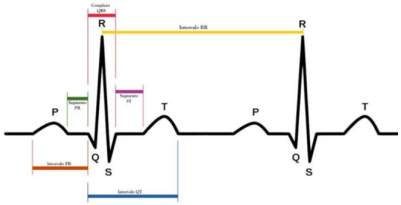
- **Filtraggio** passa-banda (0.5–40 Hz)
- **Normalizzazione** Min-Max Scaling
- **Segmentazione** in finestre temporali di 10 secondi



Intervalli RR

Gli intervalli **RR** rappresentano i tempi che intercorrono tra due battiti cardiaci consecutivi, misurati come la distanza tra i picchi R dei complessi QRS nel segnale ECG.

- Sono fondamentali per analizzare la **variabilità del ritmo cardiaco**.
- Permettono l'estrazione delle **feature**.
- Riflettono direttamente la regolarità o l'irregolarità del ritmo, utile per identificare condizioni come la **fibrillazione atriale**.



Feature

Le feature estratte si suddividono in tre categorie:

- Feature statistiche classiche: Heart Rate, Mean RR, STDRR, RMSSD.
- Feature non lineari: SD1, Sample Entropy, Approximate Entropy.
- Feature PRSA-based: Capacità di Decelerazione (DC).

segment	label	Heart Rate	Mean RR	STD RR	RMSSD	SD1	SampEn	ApEn	DC
0	N	78.92	0.7617	0.0332	0.0232	0.0164	-0.7828	-0.7828	0.0458
1	N	63.20	0.9662	0.1172	0.1295	0.0916	-0.7256	-0.7256	0.0044
2	N	78.80	0.7736	0.1111	0.1333	0.0943	-0.7688	-0.7688	0.0035
3	AF	66.36	0.9358	0.1790	0.2285	0.1616	-0.6771	-0.6771	0.1246
4	AF	74.31	0.8326	0.1515	0.2162	0.1528	-0.7533	-0.7533	0.0263

Algoritmi di classificazione

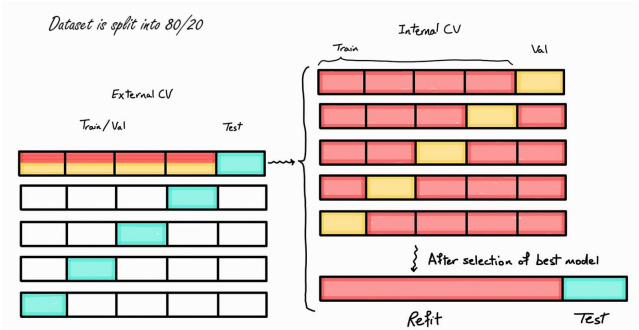
Per la classificazione automatica dei segmenti ECG sono stati testati i seguenti algoritmi di Machine Learning supervisionato:

- Random Forest
- Support Vector Machine
- K-Nearest Neighbors
- Gradient Boosting Classifier

Le performance dei modelli sono state valutate attraverso **accuratezza**, **sensibilità**, **specificità** e **f1-Score**.

Addestramento e selezione degli iperparametri con Cross Validation

Per ottimizzare i modelli, è stata utilizzata la **Grid Search con Cross Validation** (CV=5), che testa diverse combinazioni di **iperparametri** per individuare la configurazione che massimizza le performance del classificatore.



Valutazione dei modelli - Esperimento n.3

Il modello **Random Forest** ha ottenuto le performance migliori tra quelli testati nella validazione incrociata tra dataset.

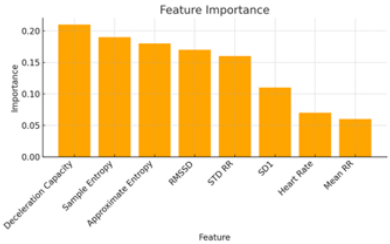
Modello	TP	TN	FP	FN	Sens	Spec	Acc	F1-s
Random Forest	647	299	127	89	0.88	0.70	0.81	0.85
Support Vector Machine (SVM)	593	265	161	143	0.80	0.62	0.73	0.79
Gradient Boosting Classifier	614	275	151	122	0.83	0.64	0.76	0.81
K-Nearest Neighbors (KNN)	605	276	156	125	0.82	0.63	0.75	0.81

Questi risultati confermano la fattibilità di un approccio basato su feature per la classificazione automatica della fibrillazione atriale su segmenti ECG.

Importanza delle feature

La metrica **Deceleration Capacity** (DC), derivata dalla tecnica PRSA, è risultata la **più informativa** nel distinguere i tracciati affetti da fibrillazione atriale.

Anche le **feature non lineari** (Sample Entropy, Approximate Entropy) hanno mostrato alta rilevanza, riflettendo l'**irregolarità** del segnale.



Conclusioni

L'approccio basato su **feature** ha dimostrato efficacia nell'identificazione automatica della fibrillazione atriale.

Risultati principali

- **Random Forest** ha ottenuto le performance migliori.
- La metrica **Deceleration Capacity (DC)** è risultata la più importante nel nostro studio.
- Buona capacità di **generalizzazione** su dataset eterogenei.

Sviluppi futuri

- Integrazione con approcci di **deep learning**.
- Applicazione del modello in scenari **real-time** e su dispositivi **wearable**.
- Studio di tecniche per la **selezione automatica delle feature** più rilevanti.



Grazie