

UNIVERSITÀ DEGLI STUDI DI MILANO

SCIENZE E TECNOLOGIE

Riassunto di tesi di

Biagio Chiaranda

(matricola 959914)

Relatore

Massimo Walter Rivolta

Corso di laurea in

INFORMATICA PER LA COMUNICAZIONE DIGITALE

Titolo dell'elaborato

SVILUPPO DI ALGORITMI DI MACHINE LEARNING PER L'IDENTIFICAZIONE DELLA FIBRILLAZIONE ATRIALE A PARTIRE DA SERIE TEMPORALI DI VARIABILITA' CARDIACA

Sviluppo di algoritmi di machine learning per l'identificazione della fibrillazione atriale a partire da serie temporali di variabilità cardiaca

Biagio Chiarandà – 959914

21 Marzo 2025

1 Ente presso cui è stato svolto il lavoro di stage

Il lavoro di stage è stato svolto presso il **Biomedical Image and Signal Processing (BiSP) Lab** dell'Università degli Studi di Milano, un laboratorio di ricerca attivo nell'ambito dell'elaborazione di segnali e immagini biomediche. Il BiSP Lab è inserito in un contesto accademico dinamico e multidisciplinare, che promuove la collaborazione tra studenti, dottorandi e ricercatori impegnati nello sviluppo di soluzioni innovative per la diagnostica e il monitoraggio clinico.

Durante questa esperienza formativa, ho avuto l'opportunità di collaborare a un progetto di ricerca incentrato sullo **sviluppo di algoritmi di machine learning per l'identificazione della fibrillazione atriale a partire da serie temporali di variabilità cardiaca** a partire da segnali elettrocardiografici (ECG). In questo percorso sono stato affiancato dal Dr. Massimo Rivolta e Dr. Moklesur Rahman, che mi hanno supportato nell'approfondimento delle competenze necessarie per contribuire attivamente al progetto.

L'ambiente di lavoro, caratterizzato da un forte spirito di cooperazione scientifica e da un approccio orientato alla ricerca applicata, ha rappresentato un contesto altamente formativo, permettendomi di integrare conoscenze teoriche e operative nell'ambito dell'elaborazione dei segnali biomedici e dell'intelligenza artificiale.

2 Contesto iniziale

La decisione di intraprendere questo percorso di stage è nata da un interesse maturato durante il mio corso di studi nei confronti dell'elaborazione dei segnali, stimolato in particolare dagli insegnamenti del Professor Roberto Sassi. Questo ambito mi ha colpito per la sua capacità di coniugare aspetti teorici e applicativi, specialmente quando integrati con le tecniche di Machine Learning, disciplina che ho sempre trovato estremamente affascinante.

All'inizio dello stage, non avevo ancora avuto occasione di applicare concretamente le tecniche di processamento dei segnali fisiologici attraverso strumenti pratici. Per questo motivo, la prima fase del lavoro è stata dedicata all'acquisizione di competenze operative, in particolare attraverso l'uso del linguaggio Python, che ho utilizzato per la prima volta in maniera strutturata per l'analisi di segnali ECG.

Durante questa fase introduttiva, ho svolto esercitazioni mirate all'elaborazione e visualizzazione di segnali biomedici, con l'obiettivo di familiarizzare con concetti fondamentali come il filtraggio, la segmentazione temporale, e l'estrazione di caratteristiche utili all'analisi automatica. Questa preparazione iniziale si è rivelata essenziale per affrontare con maggiore consapevolezza le fasi successive del progetto, incentrate sullo sviluppo di modelli predittivi per l'identificazione della fibrillazione atriale.

3 Obiettivi del lavoro

L'obiettivo principale del lavoro era lo sviluppo di algoritmi di Machine Learning in grado di identificare automaticamente episodi di fibrillazione atriale a partire da segnali elettrocardiografici. Tale finalità si inserisce in un contesto clinico e tecnologico di crescente interesse, volto a supportare la diagnosi precoce e il monitoraggio remoto delle aritmie cardiache attraverso strumenti automatici e non invasivi.

Inizialmente, il lavoro si proponeva di:

- Analizzare e comprendere le caratteristiche distintive della fibrillazione atriale nei segnali ECG, con particolare attenzione agli indicatori temporali e frequenziali.
- Applicare tecniche di pre-processing ai segnali, al fine di migliorare la qualità dei dati e rendere più affidabile l'estrazione delle caratteristiche (feature extraction).
- Sperimentare l'uso di metriche derivate dall'analisi della variabilità della frequenza cardiaca e della tecnica Phase-Rectified Signal Averaging per evidenziare pattern rilevanti associati alla patologia.
- Sviluppare e confrontare modelli di classificazione (ad es. Random Forest, SVM, KNN, Gradient Boosting), valutandone le prestazioni tramite tecniche di validazione incrociata e metriche standard (accuratezza, sensibilità, specificità, F1-score).
- Verificare la generalizzabilità dei modelli su dati provenienti da diversi dataset pubblici, con l'obiettivo di costruire una pipeline robusta ed efficace per la classificazione automatica della fibrillazione atriale.

Questi obiettivi hanno guidato lo sviluppo progressivo del progetto, strutturato in fasi di apprendimento teorico, implementazione pratica, sperimentazione e valutazione.

4 Descrizione del lavoro svolto

La fibrillazione atriale rappresenta l'aritmia cardiaca sostenuta più comune e costituisce una delle principali cause di ictus e altre gravi complicanze cardiovascolari. La diagnosi precoce riveste un ruolo cruciale nella prevenzione e nella gestione efficace di questa condizione clinica.

Nel presente lavoro è stata analizzata la possibilità di identificare automaticamente casi di fibrillazione atriale a partire da segnali ECG, attraverso l'elaborazione di serie temporali derivate dalla variabilità della frequenza cardiaca.

A tale scopo, sono stati utilizzati due dataset pubblici ampiamente riconosciuti dalla comunità scientifica:

- **PhysioNet/Computing in Cardiology Challenge 2017**: contiene registrazioni ECG monoderivazione di breve durata (9-60 secondi), annotate in quattro classi. Sono stati selezionati esclusivamente i segmenti etichettati come "N" (Normale) e "AF" (Fibrillazione Atriale), successivamente segmentati in finestre uniformi di 10 secondi.
- **MIT-BIH Atrial Fibrillation Database (AFDB)**: comprende registrazioni a lunga durata (fino a 10 ore) con annotazioni dettagliate degli episodi di fibrillazione atriale. Anche in questo caso sono stati estratti segmenti di 10 secondi direttamente dagli episodi annotati.

A partire da questi dati, sono stati condotti tre esperimenti principali:

- **Esperimento 1**: addestramento e validazione del modello su un ampio dataset bilanciato (PhysioNet 2017), segmentato in finestre regolari di 10 secondi e suddiviso in training e test assicurando la separazione tra pazienti.
- **Esperimento 2**: addestramento e validazione su un sottoinsieme casuale del secondo dataset (MIT-BIH AFDB), mantenendo anche in questo caso la separazione tra pazienti, al fine di testare la robustezza del modello su dati variabili e realistici.

- **Esperimento 3**: validazione incrociata tra dataset, con addestramento su segmenti del PhysioNet 2017 e test su dati del MIT-BIH AFDB. Questo ha permesso di valutare la capacità di generalizzazione del modello su fonti differenti, simulando un contesto clinico reale.

Prima dell'estrazione delle feature, i segnali ECG sono stati sottoposti a una fase di preprocessamento che ha incluso:

- **Filtraggio passa-banda (0.5-40 Hz)**: per rimuovere componenti indesiderate a bassa e alta frequenza, preservando la banda utile del segnale ECG.
- **Normalizzazione (Min-Max Scaling)**: per riportare le ampiezze dei segnali in un intervallo comune, eliminando le differenze di scala tra registrazioni provenienti da dispositivi diversi.
- **Segmentazione in finestre temporali di 10 secondi**: fase necessaria per uniformare la durata dei segmenti ECG da analizzare. A seconda del dataset, la segmentazione è stata effettuata in modo differente: nel caso del PhysioNet Challenge 2017, le registrazioni sono state suddivise in finestre regolari di 10 secondi, mentre nel MIT-BIH AFDB, gli episodi annotati di fibrillazione atriale e ritmo normale sono stati estratti e suddivisi in segmenti della stessa durata.

Successivamente, è stato effettuato il **rilevamento dei picchi R** tramite un algoritmo basato su derivata e modulo del segnale. Ciò ha permesso di calcolare gli intervalli RR, base per l'estrazione delle metriche legate alla variabilità della frequenza cardiaca.
Le feature estratte si suddividono in tre categorie principali:

- **Feature statistiche classiche**: Heart Rate, Mean RR, STDRR, RMSSD.
- **Feature non lineari**: SD1, Sample Entropy, Approximate Entropy.
- **Feature PRSA-based**: Capacità di Decelerazione (DC).

Per la classificazione automatica dei segmenti ECG sono stati testati i seguenti algoritmi di Machine Learning supervisionato:

- Random Forest
- Support Vector Machine (SVM)
- K-Nearest Neighbors (KNN)
- Gradient Boosting Classifier

5 Tecnologie coinvolte

Durante lo svolgimento del lavoro sono state utilizzate e approfondite diverse tecnologie e strumenti, sia di natura teorico-metodologica che pratica, con particolare riferimento all'ambito dell'elaborazione dei segnali biomedici e del Machine Learning. Di seguito si elencano le principali:

- **Linguaggio Python**: utilizzato come strumento principale per la scrittura di script e lo sviluppo dell'intera pipeline di analisi. È stato impiegato per l'importazione, il preprocessing, la segmentazione dei segnali, l'estrazione delle feature e l'addestramento dei modelli di classificazione.
- **Librerie scientifiche Python**:
  - `NumPy`, `Pandas`, `SciPy`: per la manipolazione di array numerici, la gestione dei dati tabellari e l'elaborazione dei segnali.
  - `Matplotlib`, `Seaborn`: per la visualizzazione dei segnali ECG e la rappresentazione grafica dei risultati sperimentali.
  - `Scikit-learn`: per l'implementazione degli algoritmi di machine learning supervisionato (Random Forest, SVM, KNN, Gradient Boosting), la selezione dei parametri tramite Grid Search e la validazione incrociata.
- **Ambiente di sviluppo**:

- `Jupyter Notebook` per la prototipazione rapida, l'esecuzione interattiva del codice e la documentazione integrata dei risultati.
- `Google Colab` per l'esecuzione su GPU/CPU cloud-based e la condivisione del codice durante le fasi intermedie di sviluppo e verifica.

L'apprendimento e l'utilizzo di queste tecnologie ha consentito non solo di raggiungere gli obiettivi scientifici del lavoro, ma anche di consolidare competenze fondamentali nel campo dell'analisi dei dati biomedici e dell'intelligenza artificiale applicata alla salute.

6 Competenze e risultati raggiunti

Il lavoro svolto ha permesso di conseguire risultati significativi rispetto agli obiettivi prefissati e di maturare competenze sia teoriche che pratiche nell'ambito dell'elaborazione dei segnali biomedici e del Machine Learning applicato alla diagnostica.

- **Risultati raggiunti rispetto agli obiettivi iniziali**: il modello Random Forest ha ottenuto le performance migliori tra quelli testati, con accuratezza fino all'81% e sensibilità dell'88% nella validazione incrociata tra dataset. Questi risultati confermano la fattibilità di un approccio basato su feature per la classificazione automatica della fibrillazione atriale su segmenti ECG. L'obiettivo di validare la generalizzazione del modello su dati eterogenei è stato quindi raggiunto con successo.
- **Insegnamenti tratti dall'esperienza**: il progetto ha consentito di comprendere a fondo le problematiche connesse all'elaborazione di dati clinici reali, caratterizzati da rumore, disomogeneità e variabilità fisiologica. È stato fondamentale apprendere come l'ingegnerizzazione di una pipeline solida (dalla pulizia del segnale alla validazione) incida direttamente sulla qualità dei risultati. Inoltre, l'esperienza ha rafforzato le competenze di programmazione scientifica in Python, nonché l'uso di tecniche di ottimizzazione e valutazione di modelli predittivi.
- **Problemi incontrati e gestione**: L'analisi della matrice di confusione ha evidenziato un numero non trascurabile di falsi negativi e falsi positivi, soprattutto nell'Esperimento 3. Tali errori sono attribuibili alla natura eterogenea del dataset MIT-BIH AFDB e alla variabilità fisiologica dei segnali, che ha reso difficile distinguere ritmi sinusali irregolari da episodi di fibrillazione atriale. Inoltre, è emersa una possibile tendenza all'overfitting, dovuta all'eccessiva adattabilità del modello alle caratteristiche del primo dataset. Nonostante l'uso della validazione incrociata, questi limiti suggeriscono la necessità di strategie più robuste, come data augmentation o modelli ensemble, per migliorare la generalizzazione.

7 Bibliografia

[1] AIAC - Associazione Italiana di Aritmologia e Cardiostimolazione. Fibrillazione atriale (af), 2020

[2] M. W. Rivolta, T. Stampalija, D. Casati, E. Ferrazzi, A. Bauer, and R. Sassi. A methodological assessment of phase-rectified signal averaging through simulated beat to-beat interval time series. In Computing in Cardiology, volume 41, pages 601–604, 2014.

[3] Joshua S Richman and J Randall Moorman. Physiological time-series analysis using approximate entropy and sample entropy. American Journal of Physiology-Heart and Circulatory Physiology, 278(6):H2039–H2049, 2000

Ultima revisione: 2 aprile 2025