Università degli Studi di Milano
FACOLTÀ DI SCIENZE E TECNOLOGIE

DIPARTIMENTO DI INFORMATICA
GIOVANNI DEGLI ANTONI



CORSO DI LAUREA TRIENNALE IN
INFORMATICA PER LA COMUNICAZIONE DIGITALE

SVILUPPO DI ALGORITMI DI MACHINE LEARNING PER L'IDENTIFICAZIONE DELLA FIBRILLAZIONE ATRIALE A PARTIRE DA SERIE TEMPORALI DI VARIABILITÀ CARDIACA

Relatore: Dr. Massimo Walter Rivolta
Correlatore: Prof. Roberto Sassi e Dr. Md Moklesur Rahman

Elaborato Finale di:
Biagio Chiarandà
Matr. Nr. 959914

Anno Accademico 2023-2024

Questo lavoro è dedicato ai miei genitori.

"La medicina è la scienza dell'incertezza e l'arte della probabilità."

— William Osler

Ringraziamenti

Desidero innanzitutto esprimere la mia profonda gratitudine ai miei genitori, per l'amore, la fiducia e il sostegno incondizionato che non mi hanno mai fatto mancare. Il loro esempio e i loro valori sono stati per me una guida costante lungo tutto questo percorso.

Un ringraziamento speciale va a mio fratello Adriano, che con la sua energia e la sua spontaneità ha saputo alleggerire anche i momenti più impegnativi, ricordandomi ogni giorno l'importanza delle cose semplici.

Con grande affetto ringrazio Giulia, donna intraprendente e determinata, per aver creduto in me e per essere sempre stata un punto di riferimento. Un pensiero commosso e riconoscente va a mio zio Giovanni, che, anche se oggi non è più con noi, ha avuto un ruolo fondamentale nella scelta e nella realizzazione di questo mio percorso: il suo incoraggiamento e la sua presenza mi hanno accompagnato sin dalla nascita.

Ringrazio con tutto il cuore i miei zii Salvo e Loredana, e i miei cugini, per il loro affetto costante e per essere sempre stati vicini a me e alla mia famiglia. Allo stesso modo, desidero ringraziare i miei zii Marcin, Luciano, Dorota ed Evelin per il loro supporto e la loro vicinanza, anche a distanza. Un pensiero va anche ai miei cugini della Polonia, che, pur vivendo lontani, mi hanno sempre fatto sentire parte di una famiglia unita e solidale.

Alla mia nonna Cristina, che nonostante la distanza è stata sempre presente nella mia vita con il suo affetto discreto ma profondo, va il mio più sincero e affettuoso ringraziamento.

Un pensiero speciale lo rivolgo al mio miglior amico e coinquilino Antonio: insieme abbiamo condiviso anni indimenticabili a Milano, fatti di crescita, risate, sfide e conquiste. La tua amicizia è stata per me una vera forza.

Un sentito ringraziamento va anche a Renata, figura che, pur non essendo parte della mia famiglia, ha saputo offrirmi un sostegno sincero e costante.

Desidero inoltre ringraziare Lina e Tina, due figure sagge e preziose che, con i loro consigli e la loro esperienza, mi hanno accompagnato in momenti di riflessione e decisione. La loro capacità di ascoltare, comprendere e offrire parole giuste al momento giusto ha rappresentato per me un riferimento importante, contribuendo a rafforzare la mia consapevolezza e la mia determinazione lungo questo cammino.

Rivolgo un sentito ringraziamento anche ai miei amici di giù, Massimiliano, Andrea, Lucrezia ed Enrica, con cui ho condiviso gite, momenti di spensieratezza e ricordi indimenticabili. La loro presenza e il loro affetto sono stati un prezioso sostegno lungo tutto questo percorso.

Ringrazio i miei amici Nicolò, Can, Antonio, Federico e Mirko con i quali ho vissuto esperienze significative che hanno arricchito questo percorso umano e accademico.

Un pensiero colmo di affetto e gratitudine va ai miei nonni, Carmela e Biagio, che purtroppo oggi non sono più presenti, ma continuano a vivere nei miei ricordi e nei valori che mi hanno trasmesso. In particolare, mio nonno Biagio è stato per me una figura fondamentale: con il suo esempio mi ha insegnato il valore del rispetto, dell'educazione e dell'onestà. Gran parte di ciò che sono oggi lo devo anche a lui, alla sua presenza discreta ma incisiva, alla sua capacità di trasmettere princìpi solidi che hanno orientato il mio percorso umano e formativo.

A tutti voi: grazie di cuore. Questa tesi è anche vostra.

Indice

Ringraziamenti

Indice

0.1 Glossario degli Acronomi 1

1 Introduzione **2**

1.1 Contesto e Problematiche 2

1.2 Machine Learning e Deep Learning per l'Analisi ECG: Introduzione e Stato dell'Arte 6

1.2.1 Machine Learning 6

1.2.2 Deep Learning 6

1.2.3 Confronto tra Machine Learning e Deep Learning 7

1.2.4 Stato dell'arte 7

1.2.5 Challenge e Competizioni per il Rilevamento della Fibrillazione Atriale 8

1.3 Obiettivi della Tesi 9

2 Materiali e metodi **10**

2.1 Dataset 10

2.2 Pre-processing 12

2.2.1 Filtraggio 12

2.2.2 Normalizzazione 13

2.2.3 Segmentazione 14

2.3 Estrazione delle Feature 15

2.3.1 Identificazione dei Picchi R 15

2.3.2 Metriche del dominio temporale 17

2.3.3 Metriche basate sulla dinamica non lineare 18

2.3.4 Metriche basate su Phase-Rectified Signal Averaging per l'analisi della variabilità cardiaca 20

2.4 Machine Learning 23

2.4.1 Algoritmi supervisionati 24
2.4.2 Metriche di Valutazione 28

3 Risultati e Discussione **32**
3.1 Analisi esplorativa dei dati 32
3.2 Addestamento dei Modelli di Machine Learning 34
3.2.1 Confronto tra Modelli di Classificazione 36
3.2.2 Analisi delle Performance del Modello Random Forest 38
3.3 Errori e casi critici 43

4 Conclusione **45**
4.1 Sviluppi futuri 46
4.2 Riassunto 48

Bibliografia **52**

0.1 Glossario degli Acronomi

AC Acceleration Capacity

AF o AFIB Fibrillazione Atriale

AI Artificial Intelligence

AFL Flutter Atriale

AUC Area Under the Curve

CNN Convolutional Neural Network

DC Deceleration Capacity

DL Deep Learning

ECG Electrocardiogramma

HRV Heart Rate Variability

J Ritmo Giunzionale

k-NN k-Nearest Neighbors

LSTM Long Short-Term Memory

ML Machine Learning

MIT-BIH Massachusetts Institute of Technology - Beth Israel Hospital

N Ritmo Normale

NLP Natural Language Processing

Nodo AV Nodo Atrio-Ventricolare

PRSA Phase-Rectified Signal Averaging

QRS Complesso QRS (depolarizzazione ventricolare)

RF Random Forest

RNN Recurrent Neural Network

ROC Receiver Operating Characteristic

SVM Support Vector Machine

Capitolo 1

Introduzione

Negli ultimi anni, il rapido sviluppo delle tecnologie digitali e dell'intelligenza artificiale ha avuto un impatto significativo in numerosi settori, tra cui la sanità e l'analisi dei dati biomedici. L'elaborazione automatizzata dei segnali fisiologici sta assumendo un ruolo sempre più centrale, permettendo di migliorare l'accuratezza delle diagnosi e di supportare i professionisti del settore medico nella rilevazione di patologie complesse.

Uno degli ambiti di maggiore interesse è l'**analisi dei segnali elettrocardiografici (ECG)**, fondamentale per la valutazione della salute cardiovascolare. Le malattie cardiache rappresentano una delle principali cause di mortalità a livello globale, e l'identificazione precoce di anomalie come la **fibrillazione atriale (AF)** può migliorare significativamente le possibilità di intervento e prevenzione.

L'applicazione di tecniche di **Machine Learning** all'analisi dei segnali ECG sta emergendo come un'alternativa promettente per l'identificazione automatica di anomalie cardiache.

Questa tesi si propone di esplorare l'uso di algoritmi di **apprendimento automatico** per la rilevazione della fibrillazione atriale a partire dai segnali ECG. L'obiettivo è dimostrare come l'analisi dei dati e le tecniche di **Machine Learning** possano contribuire all'identificazione automatizzata di patologie cardiache, fornendo strumenti utili per migliorare la classificazione della fibrillazione atriale e, più in generale, per supportare la ricerca nel campo dell'elaborazione dei segnali biomedici.

1.1 Contesto e Problematiche

Le **aritmie cardiache** sono disturbi della normale sequenza di attivazione elettrica del cuore, che possono manifestarsi con alterazioni della frequenza, della regolarità o della propagazione dell'impulso elettrico. Normalmente, il ritmo cardiaco è regolato dal nodo senoatriale, situato nell'atrio destro, che agisce come pacemaker naturale generando impulsi elettrici sincronizzati. Questi impulsi vengono trasmessi al nodo atrioventricolare

e poi lungo il sistema di conduzione ventricolare, coordinando la contrazione degli atri e dei ventricoli in modo efficiente.

Quando questo meccanismo viene alterato, possono verificarsi diverse forme di aritmia, tra cui:

- **Tachicardia**: un aumento anomalo della frequenza cardiaca, che può essere sopraventricolare (come la tachicardia atriale o la tachicardia da rientro nodale) o ventricolare, con implicazioni più gravi.
- **Bradicardia**: una riduzione della frequenza cardiaca, spesso legata a una disfunzione del nodo senoatriale o a un blocco atrioventricolare.
- **Extrasistoli**: battiti prematuri dovuti a impulsi ectopici che possono originare dagli atri o dai ventricoli.
- **Flutter atriale**: un'aritmia atriale caratterizzata da impulsi elettrici rapidi ma regolari che causano una contrazione atriale inefficace.
- **Fibrillazione atriale**: un'alterazione del ritmo cardiaco caratterizzata da un'attività elettrica rapida e disorganizzata degli atri. Questo causa una contrazione atriale inefficace e irregolare, che si traduce in un ritmo cardiaco irregolare e spesso accelerato.

Tra le varie aritmie, una delle più comuni e clinicamente rilevanti è la **fibrillazione atriale**.

La fibrillazione atriale è un'aritmia cardiaca caratterizzata da un'attività elettrica caotica e disorganizzata a livello degli atri, che compromette la contrazione efficace e regolare del cuore. In condizioni fisiologiche, il ritmo cardiaco è controllato dal nodo senoatriale, il quale genera impulsi elettrici regolari e coordinati, responsabili della sincronizzazione tra la contrazione degli atri e quella dei ventricoli.

Nella fibrillazione atriale, invece, si verificano impulsi multipli e asincroni, causando un battito cardiaco irregolare e spesso accelerato. A livello fisiologico, questa alterazione impedisce agli atri di contrarsi in modo efficace, riducendo la loro capacità di pompare il sangue nei ventricoli. Questa condizione può determinare una riduzione del flusso sanguigno e un ristagno del sangue negli atri, con potenziali implicazioni cliniche.

La fibrillazione atriale può essere episodica o cronica e la sua insorgenza è spesso associata a patologie cardiovascolari preesistenti, ipertensione, diabete, malattie polmonari e altri fattori di rischio. La sua diffusione e tendenza a progredire nel tempo rendono necessaria la ricerca di metodi di identificazione e monitoraggio sempre più precisi ed efficienti. La fibrillazione atriale può essere riconosciuta in un elettrocardiogramma (v. Figura 1) attraverso due caratteristiche:

- scomparsa delle onde di attivazione atriale (onde P), che vengono sostituite da rapide oscillazioni della linea isoelettrica, dette onde di fibrillazione (onde f). Le onde f sono del tutto irregolari, con continue variazioni di forma, di voltaggio e degli intervalli f-f, hanno frequenza molto elevata (400- 600/minuto) e durano per tutto il ciclo cardiaco, determinando un aspetto frastagliato della linea isoelettrica;
- irregolarità degli intervalli R-R in corso di AF: un grande numero di impulsi di origine atriale raggiunge la giunzione atrioventricolare, ma solo una parte di essi viene effettivamente trasmessa ai ventricoli. La quantità di impulsi che raggiunge i ventricoli dipende, infatti, dalle caratteristiche elettrofisiologiche del nodo AV e dalle altre porzioni del sistema di conduzione, dalla presenza di eventuali vie accessorie, dal tono del sistema nervoso autonomo e dall'azione di farmaci concomitanti. Tutte queste variabili contribuiscono alla costante variazione di durata degli intervalli R-R .

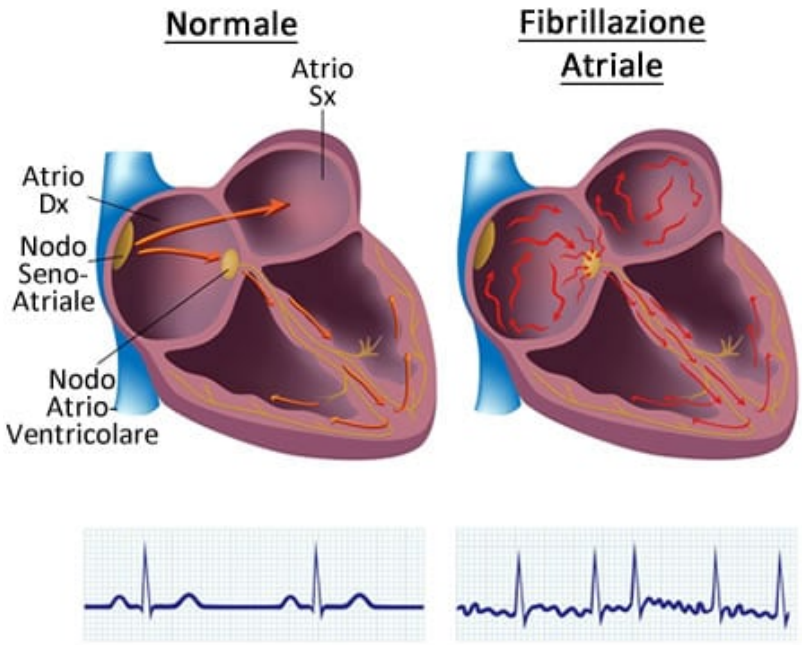


Figura 1: Differenza tra ritmo normale e ritmo con fibrillazione atriale.

La fibrillazione atriale può manifestarsi con un'ampia gamma di sintomi, che variano in intensità e frequenza a seconda delle caratteristiche del paziente e della gravità

dell'aritmia. Alcuni individui possono essere asintomatici, mentre altri avvertono sintomi significativi che influenzano la qualità della vita. I sintomi più comuni associati alla fibrillazione atriale sono riportati nella Tabella 1 (fonte: [1]).

I sintomi più comuni riportati dai pazienti con fibrillazione atriale includono:

- **Palpitazioni**: Sensazione di battito cardiaco **irregolare, accelerato o "saltato"**. È uno dei sintomi più frequenti e spesso il primo a essere notato dai pazienti.
- **Dispnea**: Difficoltà respiratoria, che può peggiorare con lo sforzo fisico a causa della ridotta efficienza del cuore nel pompare sangue ossigenato.
- **Astenia**: Sensazione di **affaticamento e debolezza**, spesso correlata alla ridotta gittata cardiaca e alla minore perfusione dei tessuti.
- **Angina**: **Dolore toracico o senso di oppressione**, che può derivare dalla minore perfusione miocardica e dall'aumento della richiesta di ossigeno da parte del cuore.
- **Vertigini**: Episodi di **instabilità o sensazione di svenimento**, legati a una ridotta perfusione cerebrale, specialmente nei casi di fibrillazione atriale con risposta ventricolare molto elevata o molto bassa.
- **Altri sintomi**: Tra cui sudorazione, ansia e disturbi del sonno, che possono derivare dall'attivazione del sistema nervoso autonomo in risposta all'aritmia.
- **Asintomatici**: Una parte dei pazienti non avverte alcun sintomo, rendendo la diagnosi di AF particolarmente difficile senza esami specifici come l'elettrocardiogramma.

Sintomi	**Totale (%)**
Palpitazioni	54,1
Dispnea	44,4
Astenia	14,3
Asintomatici	11,4
Vertigini	10,4
Angina	10,1
Altri	0,9

Tabella 1: Distribuzione percentuale dei sintomi. Fonte: [1].

1.2 Machine Learning e Deep Learning per l'Analisi ECG: Introduzione e Stato dell'Arte

Negli anni sono stati sviluppati diversi approcci per rilevare le aritmie cardiache a partire dai segnali ECG. L'interpretazione manuale dei tracciati ECG può risultare complessa e soggetta a variabilità, specialmente in presenza di segnali di bassa qualità. Per affrontare questa sfida, sono emersi due principali approcci per l'identificazione della fibrillazione atriale: il **Machine Learning** e il **Deep Learning**.

1.2.1 Machine Learning

L'applicazione del Machine Learning alla classificazione della fibrillazione atriale si basa sull'estrazione di caratteristiche dai segnali ECG, seguita dall'addestramento di modelli supervisionati o non supervisionati per la classificazione. Il processo prevede il filtraggio e la segmentazione del segnale per ridurre il rumore e migliorare la qualità dei dati. Successivamente, vengono estratte caratteristiche rilevanti, come la variabilità degli intervalli RR o parametri derivati dall'analisi spettrale e non lineare.

La selezione delle caratteristiche più significative contribuisce a migliorare le prestazioni del modello, riducendo la complessità computazionale. Algoritmi come **Support Vector Machines (SVM)**, **Random Forest (RF)** e **k-Nearest Neighbors (k-NN)** vengono utilizzati per classificare la presenza o assenza della fibrillazione atriale. La validazione dei modelli avviene attraverso tecniche come la **cross-validation**, mentre metriche come **accuratezza, sensibilità e specificità** forniscono una misura della loro efficacia.

Uno dei principali vantaggi di questo approccio è la maggiore interpretabilità rispetto alle reti neurali, grazie alla possibilità di comprendere il contributo delle singole caratteristiche alla classificazione. Tuttavia, il machine learning richiede un'accurata selezione delle feature, che può limitare la capacità di catturare pattern complessi nel segnale.

1.2.2 Deep Learning

Il deep learning, sottoinsieme del Machine Learning, si basa su reti neurali artificiali profonde, progettate per apprendere rappresentazioni complesse dei dati attraverso più livelli gerarchici. L'introduzione di queste tecniche ha rivoluzionato l'analisi dei segnali ECG, consentendo ai modelli di apprendere automaticamente caratteristiche rilevanti direttamente dai dati grezzi, senza la necessità di una fase esplicita di estrazione delle feature. Le reti convoluzionali (**CNN**) hanno dimostrato particolare efficacia nell'estrazione automatica di pattern significativi dai segnali ECG, migliorando la capacità di discriminare tra ritmo sinusale e fibrillazione atriale. Le reti ricorrenti (**RNN**) e le **Long Short-Term Memory (LSTM)** si sono rivelate particolarmente utili nell'analisi delle serie temporali, in quanto riescono a catturare le dipendenze a lungo termine nei segnali ECG.

L'adozione di architetture ibride, che combinano CNN e LSTM, ha migliorato ulteriormente le prestazioni dei modelli, sfruttando la capacità delle CNN di estrarre feature rilevanti e la memoria delle LSTM di analizzare l'andamento temporale del segnale. Più recentemente, i modelli basati su **transformers** stanno emergendo come alternativa promettente grazie alla loro capacità di catturare relazioni a lungo raggio nei dati.

Il principale svantaggio del deep learning è la necessità di grandi quantità di dati etichettati per l'addestramento e la minore interpretabilità rispetto ai modelli di machine learning tradizionali.

1.2.3 Confronto tra Machine Learning e Deep Learning

Per confrontare i due approcci, la Tabella 2 riassume le principali differenze:

Caratteristica	**Machine Learning**	**Deep Learning**
Feature Extraction	Necessaria (manuale)	Automatica (imparata dalla rete)
Interpretabilità	Alta (feature definite)	Bassa
Complessità Computazionale	Minore	Maggiore
Necessità di Dati	Relativamente bassa	Molto alta
Esempi di Modelli	SVM, Random Forest, k-NN	CNN, LSTM, Transformers

Tabella 2: Confronto tra Machine Learning e Deep Learning nella rilevazione della fibrillazione atriale.

1.2.4 Stato dell'arte

Negli ultimi anni, numerosi studi scientifici hanno affrontato il problema della rilevazione automatica della fibrillazione atriale a partire da segnali ECG, adottando sia approcci tradizionali di machine learning che tecniche avanzate di deep learning.

Uno studio significativo [2] ha dimostrato che un modello deep learning basato su CNN addestrato su oltre 90.000 ECG monotraccia era in grado di raggiungere prestazioni comparabili a quelle di un cardiologo esperto nella classificazione di aritmie, compresa la fibrillazione atriale. Questo risultato ha evidenziato il potenziale del deep learning nell'ambito diagnostico, pur sollevando questioni relative alla trasparenza e interpretabilità clinica.

Ulteriormente, [3] hanno esplorato l'utilizzo di reti neurali per la predizione della fibrillazione atriale in pazienti che non presentano sintomi evidenti al momento della registrazione ECG, aprendo scenari interessanti per il rilevamento precoce.

Recenti ricerche si stanno orientando verso l'uso di modelli basati su **transformer** (come quelli introdotti da Vaswani et al. nel contesto del NLP), adattati al dominio biomedico. In un altro studio [4], gli autori mostrano come i transformer possano superare le

prestazioni delle architetture CNN-LSTM in alcuni compiti di classificazione ECG, grazie alla loro capacità di modellare relazioni globali e temporali nei segnali.

Questi contributi testimoniano la crescente maturità del campo e la varietà di approcci disponibili, ognuno con punti di forza specifici in base al tipo di dati, alla disponibilità di etichette e al contesto clinico di applicazione.

1.2.5 Challenge e Competizioni per il Rilevamento della Fibrillazione Atriale

Per favorire il progresso tecnologico, sono state organizzate numerose **challenge e competizioni internazionali**, coinvolgendo ricercatori e aziende del settore. Iniziative come il **PhysioNet Computing in Cardiology Challenge** [5] hanno messo a disposizione dataset pubblici di segnali ECG, incentivando lo sviluppo di algoritmi avanzati per la classificazione delle aritmie cardiache.

Questi eventi hanno permesso di testare l'efficacia dei modelli su dati reali e di confrontare le diverse strategie adottate dalla comunità scientifica. L'accesso a dataset standardizzati e la collaborazione tra esperti hanno accelerato l'innovazione, portando a soluzioni sempre più affidabili e performanti per la diagnosi automatizzata della fibrillazione atriale.

1.3 Obiettivi della Tesi

L'obiettivo di questa tesi è evidenziare il potenziale delle moderne tecnologie, in particolare dell'intelligenza artificiale e del machine learning, nell'ambito della diagnosi automatizzata della fibrillazione atriale. L'analisi dei segnali ECG tramite algoritmi avanzati rappresenta una svolta significativa nella medicina digitale, offrendo strumenti sempre più precisi, veloci e accessibili per il riconoscimento delle aritmie cardiache.

La fibrillazione atriale è una patologia di grande rilevanza clinica, associata a un aumentato rischio di ictus, insufficienza cardiaca e altre complicanze cardiovascolari. La sua natura spesso silente rende la diagnosi precoce essenziale per prevenire eventi avversi e migliorare la qualità della vita dei pazienti. L'impiego di strumenti tecnologici avanzati può quindi diventare cruciale non solo per la diagnosi, ma anche per la **prevenzione**, consentendo di individuare precocemente i soggetti a rischio e intervenire tempestivamente con strategie terapeutiche adeguate.

Nonostante i progressi tecnologici a livello globale, l'adozione di queste soluzioni nel nostro paese è ancora limitata. Questa ricerca mira a dimostrare come l'integrazione di tecnologie avanzate possa migliorare l'efficienza diagnostica e il monitoraggio delle patologie cardiache, riducendo il carico sul sistema sanitario e garantendo diagnosi tempestive e affidabili. Comprendere e sfruttare appieno le potenzialità di questi strumenti è fondamentale affinché possano essere adottati su larga scala, contribuendo a una trasformazione del settore sanitario verso un approccio più innovativo.

Capitolo 2

Materiali e metodi

2.1 Dataset

Per l'analisi e lo sviluppo degli algoritmi di machine learning, sono stati utilizzati due dataset pubblicamente disponibili su **PhysioNet**:

- PhysioNet/Computing in Cardiology Challenge 2017 [5].
- MIT-BIH Atrial Fibrillation Database (AFDB) [6].

Il primo dataset impiegato in questo studio è quello della PhysioNet/Computing in Cardiology Challenge 2017 (CinC 2017), progettato per la classificazione automatica dei ritmi cardiaci a partire da segnali ECG acquisiti tramite **dispositivi portatili**. Questo dataset include un'ampia raccolta di segnali ECG a **singola derivazione**, provenienti da diverse fonti, e caratterizzati da una durata variabile, che può andare da pochi secondi a diversi minuti. Tutti i segnali sono stati acquisiti con una **frequenza di campionamento pari a 300 Hz**, garantendo una risoluzione temporale adeguata per l'analisi della variabilità del ritmo cardiaco e delle caratteristiche morfologiche dell'onda ECG. Ogni segnale è stato registrato con una risoluzione di **16 bit** e un'ampiezza variabile, dipendente dal dispositivo utilizzato per l'acquisizione. Poiché i segnali provengono da dispositivi portatili eterogenei, la gamma di ampiezza non è uniforme tra tutte le registrazioni, e non è specificata una scala fissa di millivolt per l'intero dataset. Le registrazioni del dataset CinC 2017 sono state annotate da esperti e suddivise in quattro classi principali: **Noisy, Normal, Other Rhythms e Atrial Fibrillation**. La classe **Noisy** comprende segnali ECG che presentano un livello di rumore elevato. La classe **Normal** include registrazioni con ritmo sinusale normale, rappresentando il comportamento fisiologico di un cuore sano. La classe **Other Rhythms** comprende una varietà di aritmie che non rientrano nella fibrillazione atriale, tra cui extrasistoli, tachicardie sopraventricolari e altri disturbi del

ritmo. Infine, la classe **Atrial Fibrillation** raccoglie i segnali in cui è stata identificata la presenza di fibrillazione atriale.

Il secondo dataset sviluppato presso il Beth Israel Deaconess Medical Center di Boston e reso disponibile tramite PhysioNet. Questo database è composto da **24 registrazioni di segnali ECG** acquisite da pazienti con episodi di fibrillazione atriale. Ogni registrazione ha una **durata di 10 ore** e, nella maggior parte dei casi, contiene due derivazioni ECG. Fanno eccezione le registrazioni identificate con i codici 00735 e 03665, che contengono una sola derivazione e riportano esclusivamente annotazioni relative al ritmo cardiaco e ai singoli battiti. I segnali sono stati acquisiti con una **frequenza di campionamento di 250 Hz**, con una risoluzione di **12-bit** e un'ampiezza compresa tra ±10 mV. Le registrazioni originali sono state ottenute utilizzando registratori ECG ambulatoriali con una banda di acquisizione che varia tra 0.1 Hz e 40 Hz. Le registrazioni del database sono accompagnate da annotazioni del ritmo, etichettate manualmente da esperti, e da annotazioni dei battiti. Le annotazioni del ritmo includono quattro categorie principali: **fibrillazione atriale (AFIB), flutter atriale (AFL), ritmo giunzionale (J) e ritmi normali (N)**. Le annotazioni dei battiti sono disponibili in due versioni: le prime, contenute nei file .qrs, sono state generate automaticamente da un algoritmo di rilevamento delle onde QRS e non sono state soggette a verifica manuale; le seconde, presenti nei file .qrsc, sono state corrette manualmente per alcuni record, risultando più affidabili. Questo dataset è ampiamente utilizzato nella ricerca clinica e nell'ambito dell'intelligenza artificiale per lo sviluppo di algoritmi di rilevamento automatico della fibrillazione atriale, grazie alla sua lunga durata e alla qualità delle annotazioni disponibili.

Per entrambi i dataset le registrazioni sono memorizzate nel formato **WFDB (WaveForm Database)**, una struttura di dati utilizzata in ambito medico per l'archiviazione e la gestione di segnali fisiologici. Per accedere e analizzare questi dati, è stata utilizzata la libreria WFDB in Python, che consente di:

- **Leggere i segnali** ECG dai file contenenti le registrazioni.
- **Ottenere le annotazioni cliniche** sui ritmi cardiaci, distinguendo tra fibrillazione atriale e ritmo normale.
- **Visualizzare e analizzare la morfologia del segnale**, la frequenza di campionamento e le caratteristiche dei ritmi cardiaci.

Caratteristica	MIT-BIH AFDB	CinC 2017
Fonte	Beth Israel Deaconess Medical Center	Vari istituti (PhysioNet)
Numero di registrazioni	24	Oltre 8.500
Durata dei segnali	10 ore ciascuno	Variabile (da 9 a 60s)
Derivazioni ECG	2	1
Frequenza di campionamento	250 Hz	300 Hz
Risoluzione	12-bit	16-bit
Categorie di ritmo	AF, AFL, J, N	Noisy, Normal, Other Rhythms, AF
Annotazioni dei battiti	Automatiche (.qrs) e manuali (.qrsc)	Annotazioni manuali

Tabella 3: Confronto tra i dataset MIT-BIH AFDB [6] e PhysioNet CinC 2017 [5].

2.2 Pre-processing

L'analisi dei segnali ECG richiede un'adeguata **pre-elaborazione** per ridurre il rumore, standardizzare le caratteristiche dei segnali ed estrarre le informazioni rilevanti per la classificazione della fibrillazione atriale. In questa fase, sono state applicate tecniche di **filtraggio, normalizzazione e segmentazione**, adattate alle caratteristiche specifiche dei dataset utilizzati, questo è stato fatto attraverso strumenti open-source messi a disposizione da PhysioToolkit, parte dell'infrastruttura PhysioNet [7].

2.2.1 Filtraggio

Il **filtraggio** è un passaggio essenziale nella fase di pre-elaborazione, poiché consente di eliminare componenti di disturbo e preservare le informazioni rilevanti per l'analisi del segnale. In questo studio, sono stati applicati **due livelli** di filtraggio con l'obiettivo di migliorare la qualità del tracciato e facilitare l'individuazione delle caratteristiche morfologiche fondamentali per la classificazione automatica dei ritmi cardiaci.

Rimozione del Rumore tramite Filtraggio Passa-Banda

Il primo step di pre-elaborazione prevede l'applicazione di un **filtro passa-banda**, che seleziona le componenti di frequenza comprese tra **0.5 Hz** e **40 Hz**. Questo intervallo è

stato scelto per garantire che il segnale conservi le informazioni necessarie per l'analisi, eliminando al contempo elementi indesiderati.

- Il limite inferiore della banda (0.5 Hz) è stato introdotto per **attenuare il rumore a bassa frequenza**, spesso dovuto a movimenti del paziente e variazioni respiratorie.
- Il limite superiore (40 Hz) consente di **ridurre il rumore ad alta frequenza**, come le interferenze muscolari e quelle derivanti dalla rete elettrica.

Questo passaggio assicura la conservazione delle componenti morfologiche essenziali, tra cui le onde **P**, **QRS** e **T**, necessarie per il riconoscimento dei pattern del segnale.

Filtraggio per l'Enfatizzazione delle Onde QRS

Dopo la rimozione del rumore, il segnale è stato sottoposto a un secondo livello di filtraggio, finalizzato a evidenziare i **complessi QRS**, la parte più prominente delle serie temporali. Per ottenere questo risultato, è stata applicata una selezione di frequenza più ristretta, mantenendo solo le componenti comprese tra **5 Hz** e **15 Hz**.

- Il limite inferiore (5 Hz) è stato scelto per **attenuare le onde P e T**, che potrebbero interferire con il rilevamento dei battiti.
- Il limite superiore (15 Hz) permette di **conservare le componenti necessarie all'identificazione dei picchi R**, eliminando quelle non informative.

2.2.2 Normalizzazione

I segnali ECG provenienti dai dataset utilizzati sono stati normalizzati, questa normalizzazione è stata eseguita sull'intero tracciato ECG di ciascuna registrazione. Per garantire una rappresentazione uniforme dei dati, è stata applicata una **normalizzazione in un intervallo predefinito**. L'operazione di normalizzazione è stata effettuata utilizzando la tecnica **min-max scaling**, preservando la forma dell'onda ECG ma eliminando le differenze di scala tra le registrazioni. Questo processo migliora la stabilità numerica degli algoritmi di apprendimento automatico e garantisce una comparabilità tra i segnali.

Formula della normalizzazione (Min-Max Scaling):

$$X' = \frac{X - X_{\min}}{X_{\max} - X_{\min}} \tag{1}$$

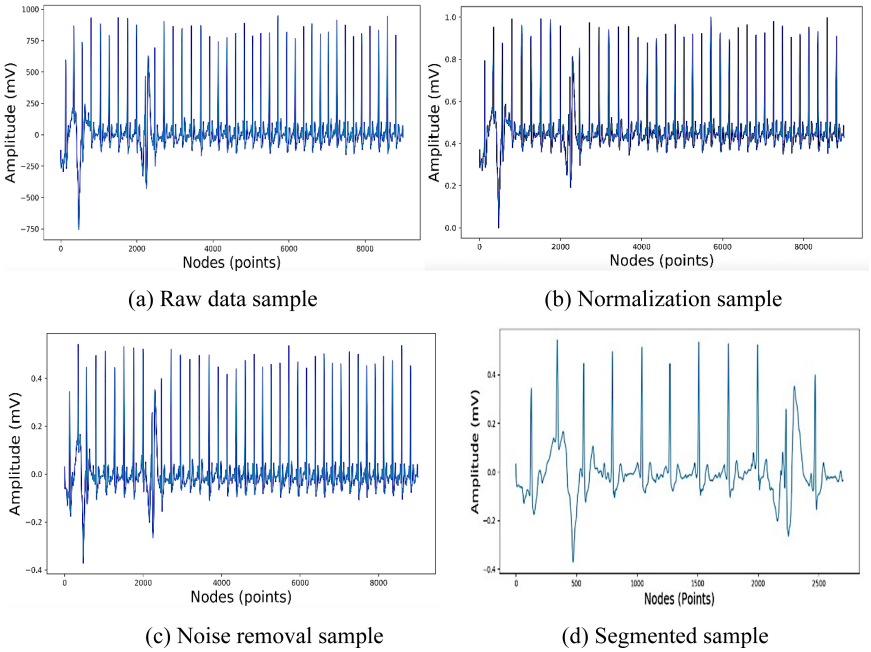
2.2.3 Segmentazione

A causa della variabilità nella lunghezza delle registrazioni ECG presenti nei dataset, è stato necessario applicare una **segmentazione adattiva dei dati**. Per questa operazione, sono stati utilizzati **due approcci distinti** in base alla durata dei segnali:

- **Segmentazione in finestre di 10 secondi**, utilizzata per il dataset PhysioNet Challenge 2017, caratterizzato da registrazioni di breve durata (9-60 secondi). I segnali sono stati suddivisi in finestre di 10 secondi, permettendo di standardizzare la lunghezza degli input per il modello di Machine Learning. Se una registrazione era più corta di 10 secondi, veniva esclusa per mantenere un dataset bilanciato.

- **Segmentazione basata sugli episodi annotati**, utilizzata per il dataset MIT-BIH Atrial Fibrillation Database, in cui le registrazioni durano circa 10 ore. Sono stati estratti solo gli episodi annotati di fibrillazione atriale e di ritmo normale, evitando di considerare intere sezioni di ritmo sinusale non rilevanti per la classificazione. Poiché ogni registrazione è estremamente lunga, è stato necessario suddividere gli episodi annotati in finestre fisse di 10 secondi, in modo da ottenere segmenti coerenti e confrontabili tra loro, e rendere il formato dei dati omogeneo rispetto al primo dataset.

  Il processo di pre-processamento applicato ai segnali ECG è illustrato nella Figura 2, che mostra le diverse fasi: il segnale originale, il filtraggio per la rimozione del rumore, la normalizzazione tramite min-max scaling e la segmentazione in finestre temporali.



(a) Raw data sample (b) Normalization sample

(c) Noise removal sample (d) Segmented sample

Figura 2: Esempio di pre-processamento di un segnale ricavato dal dataset CinC 2017 [5].

2.3 Estrazione delle Feature

L'analisi del segnale ECG si basa sull'individuazione di parametri che permettono di caratterizzare in maniera quantitativa il comportamento del ritmo cardiaco. Tra le informazioni fondamentali per lo studio del segnale elettrocardiografico, l'identificazione dei **picchi R** rappresenta il primo passo per ottenere una valutazione accurata della frequenza cardiaca e della sua variabilità.

2.3.1 Identificazione dei Picchi R

I **picchi R** corrispondono alle componenti di massima ampiezza del **complesso QRS** e sono gli elementi chiave per determinare il ritmo cardiaco. La loro identificazione consente di misurare con precisione gli intervalli temporali tra un battito e il successivo, fornendo informazioni essenziali sulla regolarità del battito cardiaco.

Infatti, dopo aver intrapreso il preprocessamento dei nostri segnali attraverso filtraggio, normalizzazione e segmentazione, si passa all'applicazione di una tecnica per rilevare i massimi del segnale, corrispondenti ai picchi R, ecco un esempio di un elettrocardiogramma come mostrato in Figura 3.

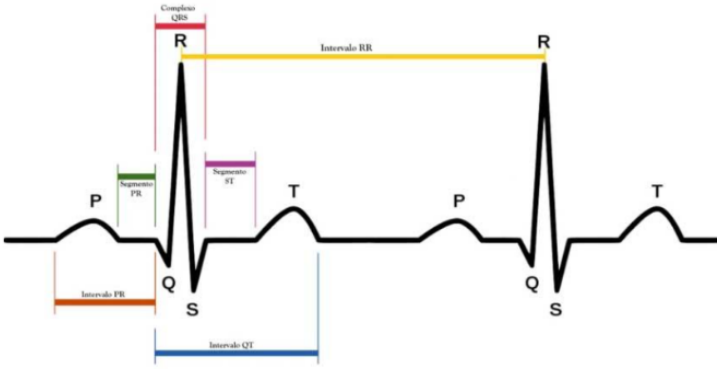


Figura 3: Schema di un elettrocardiogramma: complesso QRS, segmenti PR e ST, intervalli PR, QT e RR.

L'identificazione dei picchi R è stata effettuata mediante la funzione `find_peaks()` della libreria `scipy.signal`, progettata per l'elaborazione e l'analisi dei segnali digitali, come nel nostro caso i segnali ECG.

Per migliorare l'affidabilità del rilevamento, la funzione è stata applicata a un segnale pre-processato ed enfatizzato, ottenuto tramite filtraggio e trasformazioni che evidenziano la morfologia dei complessi QRS. Inoltre, per evitare falsi positivi dovuti a fluttuazioni minori, è stata imposta una distanza minima tra due picchi consecutivi, coerente con la frequenza di campionamento, corrispondente a un intervallo minimo di 0.6 secondi.

Detto questo, otteniamo l'intervallo RR che è il tempo che intercorre tra due picchi R consecutivi all'interno del tracciato ECG. Essendo direttamente correlato al battito cardiaco, questo parametro fornisce informazioni essenziali sulla regolarità del ritmo e sulla presenza di eventuali aritmie. L'analisi della sua distribuzione permette di identificare anomalie nella sequenza temporale dei battiti e rappresenta una base solida per il calcolo di ulteriori feature legate alla dinamica del cuore.

Per analizzare la variabilità del ritmo cardiaco, è necessario calcolare gli intervalli di tempo tra due battiti consecutivi, noti come **intervalli RR**, ottenuti dalla differenza temporale tra due picchi R successivi nel tracciato ECG:

$$RR_i = R_{i+1} - R_i \tag{2}$$

Dopo aver ottenuto gli intervalli RR per ciascun segmento, si è passati al calcolo di diverse metriche derivate da essi. Queste metriche sono essenziali per quantificare la

variabilità del ritmo cardiaco e vengono utilizzate come feature per addestrare e validare i modelli di machine learning.

Le metriche calcolate possono essere suddivise in diverse categorie:

- **Metriche del dominio temporale**, che forniscono informazioni sulla distribuzione degli intervalli RR e sulla loro variabilità nel tempo.
- **Metriche basate sulla dinamica non lineare**, che analizzano la complessità del segnale e la sua prevedibilità.
- **Metriche basate su Phase-Rectified Signal Averaging per l'analisi della variabilità cardiaca**, che consentono di valutare la risposta del sistema cardiovascolare.

2.3.2 Metriche del dominio temporale

Queste metriche analizzano la variabilità della frequenza cardiaca nel tempo, basandosi sugli **intervalli RR**, i quali rappresentano la distanza temporale tra due picchi R consecutivi nel tracciato ECG e sono generalmente espressi in **millisecondi (ms)**.

- **Media degli intervalli RR (Mean RR)**: rappresenta il tempo medio tra due battiti successivi, nel nostro caso un alta variabilità indica una discriminante importante per il nostro studio.

$$\text{Mean RR} = \frac{1}{N} \sum_{i=1}^{N} \text{RR}_i \tag{3}$$

  dove:
  - RR_i sono gli intervalli RR
  - N è il numero totale degli intervalli
  - Mean RR ha la stessa unità di misura dei RR_i, ovvero ms

- **Frequenza Cardiaca (HR - Heart Rate)**: misura la velocità del battito cardiaco in battiti per minuto (bpm). Nella fibrillazione atriale, la frequenza cardiaca è spesso elevata (tachicardia), ma può anche essere normale o addirittura bassa in alcuni casi. Tuttavia, la caratteristica principale è l'irregolarità del battito, che si riflette in una variabilità anomala degli intervalli RR.

$$\text{HR} = \frac{60}{\text{Mean } RR} \tag{4}$$

  dove:
  - HR è la frequenza cardiaca in battiti per minuto (bpm)
  - *Mean* RR è l'intervallo RR medio in secondi
  - Di conseguenza, HR ha unità di misura bpm

- **Deviazione Standard degli intervalli RR (STDRR)**: quantifica la dispersione degli intervalli RR, indicando la variabilità complessiva del ritmo cardiaco, la deviazione standard degli intervalli RR è molto elevata nella Fibrillazione atriale a causa dell'irregolarità del ritmo cardiaco. Questa metrica è uno degli indicatori più forti della presenza di AF.

$$\text{STDRR} = \sqrt{\frac{1}{N}\sum_{i=1}^{N}(RR_i - \text{Mean RR})^2} \tag{5}$$

dove:
- RR_i sono gli intervalli RR
- $MeanRR$ è la media degli intervalli RR
- N è il numero totale degli intervalli
- STDRR è espresso in ms

- **RMSSD (Root Mean Square of Successive Differences)**: misura la variabilità a breve termine, focalizzandosi sulle differenze tra battiti consecutivi. Questa metrica rifletta l'instabilità del ritmo cardiaco.

$$\text{RMSSD} = \sqrt{\frac{1}{N-1}\sum_{i=1}^{N-1}(RR_{i+1} - RR_i)^2} \tag{6}$$

dove:
- $RR_{i+1} - RRi$ è la differenza tra due intervalli RR consecutivi
- N è il numero totale degli intervalli
- RMSSD ha unità di misura pari a ms

2.3.3 Metriche basate sulla dinamica non lineare

Il battito cardiaco non segue una dinamica perfettamente regolare, ma è continuamente regolato dal sistema nervoso autonomo. Gli approcci lineari (statistiche classiche come media, deviazione standard, ecc.) non catturano completamente la complessità della regolazione cardiaca, soprattutto in presenza di aritmie. Per questo motivo, sono state introdotte tecniche di analisi non lineare come l'entropia approssimata (ApEn) e l'entropia campionaria (SampEn), che misurano il grado di irregolarità e imprevedibilità di una serie temporale fisiologica [8].

- **SD1 (Poincaré Plot Short-Term Variability)**: analizza la dispersione degli intervalli RR nel breve termine, utile per caratterizzare la variabilità del ritmo per indicare un ritmo normale o un ritmo caotico.

$$SD1 = \frac{1}{\sqrt{2}} \sqrt{\frac{1}{n-1} \sum_{i=1}^{n-1} (RR_{i+1} - RR_i)^2} \tag{7}$$

Nonostante la SD1 sia matematicamente correlata alla RMSSD, dalla quale differisce soltanto per un fattore costante, è stata inclusa nel presente studio in quanto costituisce una metrica comunemente impiegata in ambito clinico per descrivere la variabilità cardiaca a breve termine. SD1 deriva dall'analisi geometrica del Poincaré Plot ed è stata utilizzata in numerosi studi per la caratterizzazione di condizioni fisiopatologiche, inclusa la fibrillazione atriale. Inoltre, la sua presenza nel set di feature consente di valutare empiricamente, attraverso tecniche di Machine Learning, il suo contributo alla capacità predittiva del modello, anche in presenza di potenziali correlazioni con altre metriche di variabilità.

- **Sample Entropy**: Indica il grado di imprevedibilità del ritmo cardiaco. Un valore basso suggerisce un battito regolare, mentre un valore alto è spesso legato a fibrillazione atriale o altre aritmie.

$$\text{SampEn}(m, r, N) = -\ln\left(\frac{A}{B}\right) \tag{8}$$

dove:
- m è la lunghezza della sequenza
- r è la soglia di similarità
- A è il numero di coppie di sequenze simili di lunghezza $m + 1$
- B è il numero di coppie di sequenze simili di lunghezza m

- **Approximate Entropy**: simile alla Sample Entropy, misura la complessità e la ripetitività del battito cardiaco. Se è basso, il ritmo è più prevedibile, mentre un valore alto indica una maggiore variabilità.

$$\text{ApEn}(m, r, N) = \phi^m(r) - \phi^{m+1}(r) \tag{9}$$

dove:

$$\phi^m(r) = \frac{1}{N-m} \sum_{i=1}^{N-m} \ln C_i^m(r)$$

e $C_i^m(r)$ conta la frazione di vettori m-dimensionali che rimangono simili entro la soglia r.

ApEn basso → Segnale regolare
ApEn alto → Segnale irregolare

2.3.4 Metriche basate su Phase-Rectified Signal Averaging per l'analisi della variabilità cardiaca

La **Phase Rectified Signal Averaging (PRSA)** è una tecnica utilizzata per analizzare la dinamica del battito cardiaco, con particolare attenzione alle variazioni di **accelerazione** e **decelerazione** negli intervalli RR.

Questi due parametri hanno ottenuto un'ampia accettazione nella comunità dell'ingegneria biomedica grazie alla loro robustezza rispetto alla qualità del segnale e alla loro sensibilità a diverse condizioni cliniche, tra cui infarto del miocardio, di stress, insufficienza cardiaca e cardiomiopatia dilatativa.
La **Capacità di Accelerazione (AC)** e la **Capacità di Decelerazione (DC)** vengono calcolate utilizzando la tecnica Phase-Rectified Signal Averaging (PRSA), come illustrato in Figura 4. La formulazione matematica delle metriche AC e DC è stata sviluppata a partire dai lavori metodologici di Bauer et al., e ulteriormente analizzata da Rivolta et al. [9]. Numerosi studi successivi [10, 11, 12] ne hanno dimostrato l'applicabilità in diversi contesti di analisi dei segnali cardiovascolari, fornendo una base solida per l'integrazione di tali metriche in pipeline di classificazione automatica basate su Machine Learning. Il metodo PRSA è progettato per stimare la regolazione autonoma della frequenza cardiaca, anche in presenza di desincronizzazioni di fase, battiti mancati e perdite di segnale.

Calcolo delle metriche DC e AC
Gli anchor points vengono identificati come i punti temporali t tali che:

$$ADC = \left\{ t : \frac{1}{T} \sum_{i=0}^{T-1} RR[t+i] > \frac{1}{T} \sum_{i=1}^{T} RR[t-i] \right\} \tag{10}$$

L'elenco delle accelerazioni AAC viene costruito invertendo la disuguaglianza:

$$AAC = \left\{ t : \frac{1}{T} \sum_{i=0}^{T-1} RR[t+i] < \frac{1}{T} \sum_{i=1}^{T} RR[t-i] \right\} \tag{11}$$

Per ciascun anchor point t, si costruisce la serie PRSA:

$$PRSA[k] = \frac{1}{N} \sum_{t \in AP} RR[t+k] \tag{12}$$

Dove AP rappresenta l'insieme degli anchor points.
Se gli anchor points sono selezionati per la **capacità di accelerazione o capacità di decelerazione**, allora:

$$DC(oAC) = \frac{1}{2s} \sum_{k=1}^{s} (PRSA[L+k] - PRSA[L-k]) \tag{13}$$

Sintetizzando, il calcolo di AC e DC richiede la specificazione di tre parametri fondamentali:

- **T**: definisce il numero di punti usato per individuare gli anchor points.
- **L**: determina l'estensione della serie PRSA
- **s**: seleziona le oscillazioni della serie PRSA che influenzano maggiormente AC e DC.

Questi parametri permettono di modulare la sensibilità di AC e DC a diverse scale temporali e frequenze del segnale cardiaco.

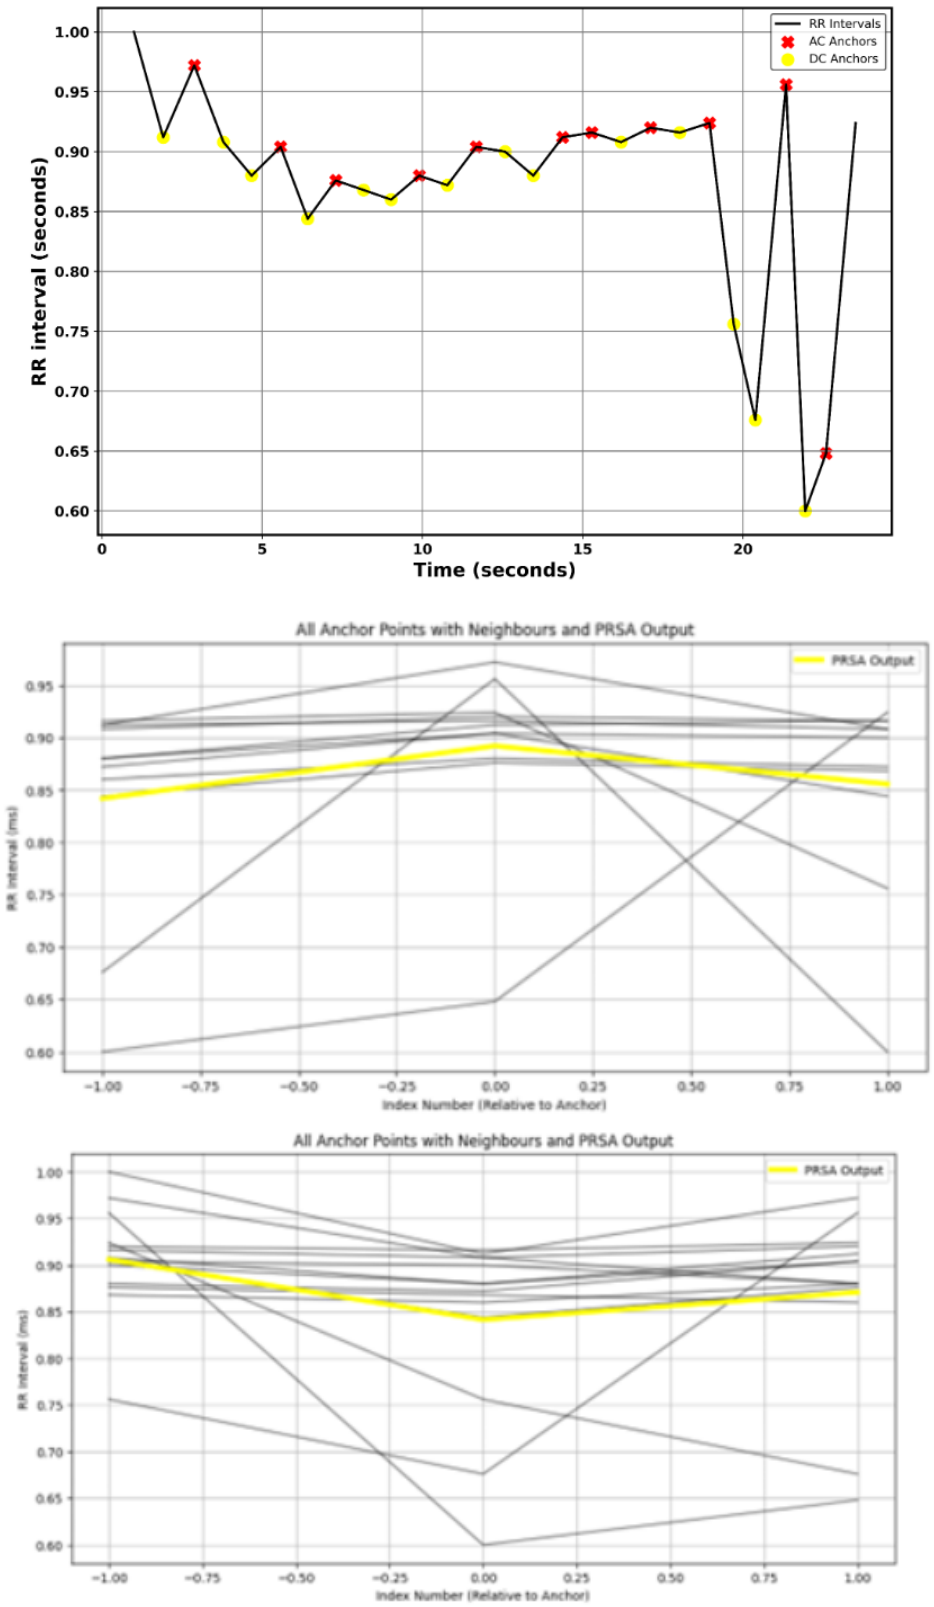


Figura 4: Analisi PRSA degli anchor points per la stima della capacità di accelerazione (AC) e decelerazione (DC). (a) Finestra temporale di 20 s con anchor points evidenziati. (b) Analisi PRSA degli anchor points per Acceleration Capacity (AC). (c) Analisi PRSA degli anchor points per Deceleration Capacity (DC).

2.4 Machine Learning

Negli ultimi decenni, il rapido sviluppo dell'**Intelligenza Artificiale** ha trasformato numerosi settori, rivoluzionando il modo in cui vengono analizzati e interpretati i dati. L'AI comprende un insieme di tecnologie e algoritmi che permettono ai sistemi informatici di simulare l'intelligenza umana, apprendere da dati ed eseguire compiti complessi senza una programmazione esplicita per ogni scenario.

Uno dei principali sottoinsiemi dell'AI è il **Machine Learning**, che si basa sull'uso di **algoritmi in grado di apprendere automaticamente** dai dati ed effettuare previsioni o classificazioni. A differenza dei tradizionali metodi computazionali, i modelli di ML non richiedono regole esplicite per ogni decisione, ma migliorano le proprie prestazioni attraverso l'esperienza e l'esposizione a nuovi dati.

Un'ulteriore evoluzione del Machine Learning è rappresentata dal **Deep Learning**, una tecnica avanzata che utilizza **reti neurali artificiali profonde** per risolvere problemi complessi, come il riconoscimento di immagini, l'elaborazione del linguaggio naturale e l'analisi di segnali fisiologici, tra cui il segnale ECG.
Nel contesto della classificazione di segnali ECG, diversi studi hanno dimostrato l'efficacia del DL nell'identificare automaticamente aritmie, inclusa la fibrillazione atriale [2, 13, 14, 15].

Esistono tre principali approcci al Machine Learning:

- **Apprendimento supervisionato (Supervised Learning)**

  Il modello viene addestrato su un dataset etichettato, in cui ogni input è associato a una risposta corretta. Esempi di algoritmi: Support Vector Machines, Random Forest, XGBoost, Reti Neurali Artificiali.

- **Apprendimento non supervisionato (Unsupervised Learning)**

  Il modello analizza i dati senza etichette, identificando strutture o pattern nascosti. Esempi di algoritmi: K-Means, Gaussian Mixture Models, DBSCAN, Autoencoder.

- **Apprendimento per rinforzo (Reinforcement Learning)**

  Il modello impara attraverso un sistema di ricompense, ottimizzando le decisioni in base ai risultati ottenuti. Esempi di algoritmi: Deep Q-Networks, Policy Gradient, Actor-Critic.

Nel presente studio, per l'analisi e la classificazione dei segnali ECG, è stato adottato un **approccio supervisionato**, sfruttando un insieme di dati etichettati per addestrare diversi modelli di Machine Learning e valutarne l'efficacia. L'obiettivo era identificare

l'algoritmo più adatto per distinguere principalmente tra ritmo sinusale normale e fibrillazione atriale, utilizzando feature estratte dai segmenti del segnale ECG, come mostrato in precedenza.

Per garantire una valutazione affidabile del modello, il dataset è stato suddiviso in due parti:

- 80% dei dati per il training, utilizzati per addestrare il modello supervisionato.
- 20% dei dati per il test, per valutare le prestazioni del modello su dati mai visti prima e verificarne la capacità di generalizzazione.

2.4.1 Algoritmi supervisionati

Per individuare il **modello più efficiente**, sono stati testati **quattro algoritmi supervisionati**, ognuno con caratteristiche diverse e capacità specifiche nell'elaborazione di dati numerici complessi come quelli derivati attraverso l'estrazione delle feature.

Random Forest

L'algoritm Random Forest ha raggiunto grande popolarità tra gli algoritmi di Machine Learning durante l'ultimo decennio in primis per le sue buone prestazioni come classificatore e in secondo luogo grazie alla sua **scalabilità** e **facilità** di utilizzo. Come suggerisce lo stesso nome, si intuisce che le foreste casuali possono essere considerate come un insieme di **alberi decisionali**. L'idea che sta alla base di Random Forest è la costruzione di un **modello robusto** mettendo insieme più sistemi di apprendimento deboli. Ogni albero genera una previsione sulla classe, e si prende come previsione del modello quella che ottiene il maggior numero di voti, come viene mostrato nella Figura 5.

Il Random Forest hanno tre iperparametri principali, che devono essere impostati prima dell'addestramento. Tra questi rientrano la dimensione minima del nodo (min samples leaf) che rappresenta il numero minimo di campioni richiesti per formare una foglia nell'albero, il numero di alberi che indica quanti alberi verranno costruiti nella foresta e il numero di funzioni campionate (max features) che determina quante caratteristiche (feature) casuali vengono selezionate per considerare la suddivisione a ciascun nodo.

Come già accennato, il Random Forest è costituito da un insieme di alberi decisionali, ciascuno addestrato su un campione casuale del dataset originale ottenuto mediante una tecnica detta **Bootstrapping**, ovvero il campionamento con reinserimento. In media, circa un terzo dei dati non viene incluso in ciascun campione e viene accantonato come dati di validazione, noto come **out-of-bag**, che verrà utilizzato in seguito per la stima dell'accuratezza del modello.

Un ulteriore elemento di casualità viene introdotto tramite la **feature bagging**, che consiste nella selezione casuale di un sottoinsieme di caratteristiche (feature) ogni volta

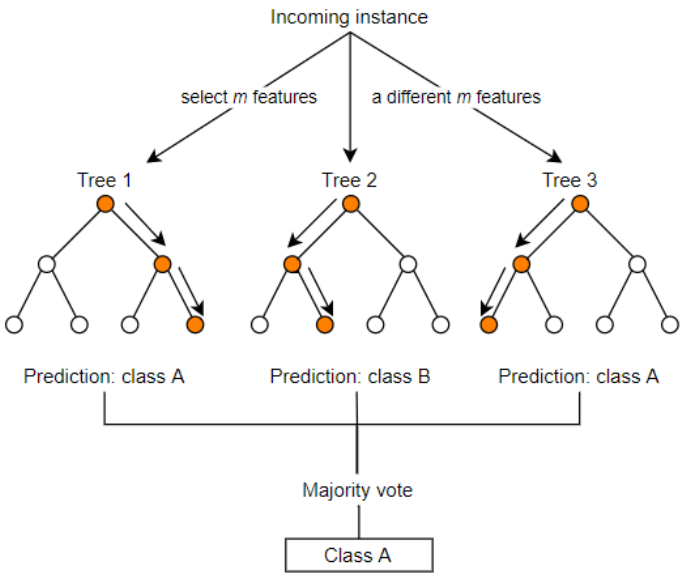


Figura 5: Decision Trees Random Forest

che un nodo di un albero deve essere suddiviso. Questo approccio riduce la correlazione tra gli alberi e aumenta la diversità all'interno della foresta, migliorando la capacità di generalizzazione del modello.

Alla fine dell'addestramento, la previsione finale viene ottenuta combinando le risposte di tutti gli alberi: nel caso della classificazione si adotta una **votazione di maggioranza**, ovvero la classe più frequentemente predetta. L'insieme dei dati out-of-bag viene infine impiegato per stimare la performance del modello in modo analogo alla validazione incrociata.

Support Vector Machine (SVM)

L'algoritmo Support Vector Machine è un classificatore supervisionato progettato per trovare il **miglior iperpiano separatore tra le classi**, **massimizzando il margine tra i punti di dati appartenenti a categorie differenti**. Questo modello è particolarmente efficace quando le classi sono ben separabili nello spazio delle feature e offre un approccio robusto sia per dati lineari che non **linearmente separabili**.

Quando i dati non sono linearmente separabili, vengono utilizzate funzioni **kernel** per trasformare i dati in uno **spazio multidimensionale**, consentendo la separazione lineare. Questo principio è illustrato in Figura 6, dove si osserva come la trasformazione del dominio consenta la separazione mediante un iperpiano. L'applicazione delle funzioni kernel è nota come "**kernel trick**", e la scelta della funzione kernel, come kernel

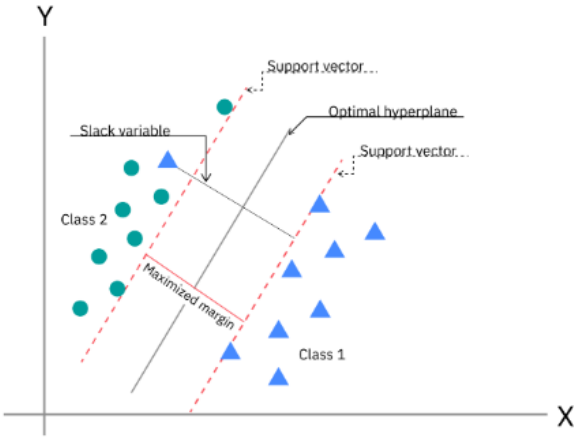


Figura 6: Rappresentazione di un classificatore SVM

lineari, kernel polinomiali, kernel RBF (Radial Basis Function) o kernel sigmoide, dipende dalle caratteristiche dei dati e dal caso d'uso specifico. Poi segue un altro parametro fondamentale, il parametro C che controlla il compromesso tra massimizzare il margine e minimizzare gli errori di classificazione sui dati di training.
Pertanto la scelta del kernel e del valore di C è cruciale per **ottimizzare le prestazioni dell'algoritmo** in base alla natura dei dati analizzati.

Gradient Boosting Classifier

Il Gradient Boosting Classifier è un algoritmo di apprendimento supervisionato basato su una combinazione di **alberi decisionali sequenziali**, che migliorano progressivamente l'accuratezza della classificazione correggendo gli errori commessi dagli alberi precedenti, come viene raffigurato nelle Figura 7. È una delle tecniche più potenti per problemi di **classificazione e regressione**, ed è spesso utilizzata in competizioni di Machine Learning per la sua elevata capacità predittiva.

Riassiumiamo il suo funzionamento, abbiamo un primo albero viene addestrato sui dati originali, cercando di prevedere correttamente la classe di ogni campione. Dopo l'addestramento del primo albero, viene calcolata la differenza tra la predizione del modello e il valore reale (errore residuo). Un nuovo albero viene addestrato per ridurre l'errore residuo dell'albero precedente. Il modello continua a migliorarsi iterativamente, riducendo progressivamente gli errori commessi. Dopo aver addestrato una serie di alberi, le loro predizioni vengono combinate in modo pesato per generare il risultato finale. Un parametro chiave del Gradient Boosting è il **learning rate**, che controlla la velocità con cui il

modello aggiorna i suoi pesi per correggere gli errori.

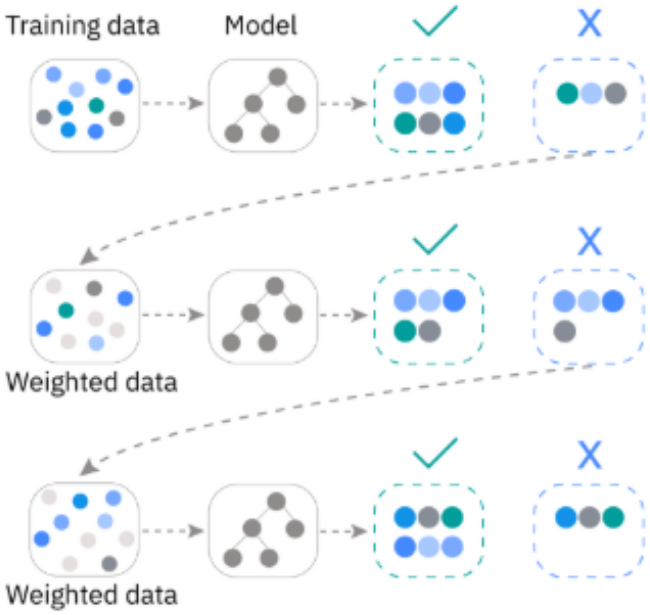


Figura 7: Gradient Boosting: miglioramento iterativo degli alberi decisionali

K-Nearest Neighbors (KNN)

L'algoritmo k-nearest neighbors è un classificatore di **apprendimento supervisionato non parametrico**, che utilizza la prossimità per effettuare classificazioni o previsioni sull'**aggregazione di un singolo punto dati**. Si tratta di uno dei metodi di classificazione e regressione più **popolari** e **semplici** attualmente utilizzati nell'apprendimento automatico. Il funzionamento dell'algoritmo è illustrato in Figura 8, dove un punto da classificare viene etichettato sulla base della maggioranza delle classi dei suoi vicini più prossimi.

Sebbene l'algoritmo KNN possa essere utilizzato sia per problemi di regressione che di classificazione, solitamente viene usato come **algoritmo di classificazione**, partendo dal presupposto che punti simili possano essere trovati vicini l'uno all'altro.
Per i problemi di classificazione, un'etichetta di classe viene assegnata sulla base di un **voto di maggioranza**, cioè viene utilizzata l'etichetta più frequentemente rappresentata in un determinato punto di dati.

Vale la pena notare che l'algoritmo KNN fa anche parte di una famiglia di modelli di "**apprendimento pigro**", cioè **memorizza** solo un set di dati di addestramento invece

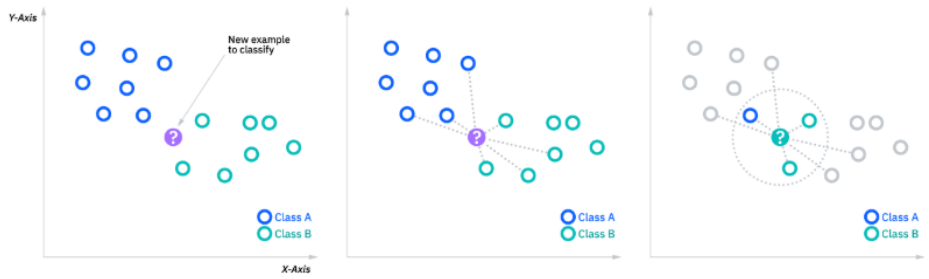


Figura 8: Diagramma KNN

di sottoporsi a una fase di addestramento. Ciò significa anche che tutti i calcoli vengono eseguiti quando si effettua una classificazione o una previsione. Poiché si affida fortemente alla memoria per memorizzare tutti i dati di addestramento, viene anche definito un un **metodo di apprendimento basato sull'istanza o sulla memoria**.

2.4.2 Metriche di Valutazione

Per valutare l'efficacia dei modelli di Machine Learning nella classificazione del ritmo cardiaco, è fondamentale analizzare le loro prestazioni attraverso diverse metriche di valutazione. Oltre all'accuratezza, vengono utilizzate altre metriche come **specificità**, **precisione**, **recall**, **F1-score**, la **matrice di confusione** e le **curve ROC e AUC** che consentono di comprendere meglio il comportamento del modello in termini di **falsi positivi** e **falsi negativi**.

Accuratezza (Accuracy)

L'accuratezza è una delle metriche più comuni per valutare un modello di classificazione ed è definita come il rapporto tra il numero di predizioni corrette e il numero totale di osservazioni nel dataset di test:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \tag{14}$$

Dove:

- TP (**True Positives**) $\rightarrow$ Campioni della classe positiva classificati correttamente.
- TN (**True Negatives**) $\rightarrow$ Campioni della classe negativa classificati correttamente.
- FP (**False Positives**) $\rightarrow$ Campioni negativi classificati erroneamente come positivi.

- FN (**False Negatives**) $\rightarrow$ Campioni positivi classificati erroneamente come negativi.

Un'alta accuratezza indica che il modello ha una buona capacità di classificazione, ma non è sufficiente quando si lavora con dataset sbilanciati, in cui una classe è molto più frequente delle altre. Nel nostro lavoro, come andremo a mostrare nel prossimo capitolo, la classe positiva sarà quella che classificherà correttamente la fibrillazione atriale.

Specificità (Specificity)

La specificità misura la capacità di un classificatore di identificare correttamente i casi negativi:

$$\text{Specificity} = \frac{TN}{TN + FP} \tag{15}$$

In altre parole, indica quanto bene il modello evita i falsi allarmi, cioè i falsi positivi.

Precisione (Precision)

La precisione misura la proporzione di campioni classificati come positivi che sono effettivamente positivi:

$$\text{Precision} = \frac{TP}{TP + FP} \tag{16}$$

Questa metrica è particolarmente importante nei contesti in cui i falsi positivi devono essere minimizzati.

Recall (Sensibilità o TPR - True Positive Rate)

Il recall misura la capacità del modello di identificare correttamente tutti i campioni appartenenti alla classe positiva:

$$\text{Recall} = \frac{TP}{TP + FN} \tag{17}$$

Un alto valore di recall significa che il modello è in grado di identificare la maggior parte dei casi positivi, ma può essere soggetto a un maggior numero di falsi positivi.

F1-score

L'F1-score è la media armonica tra precisione e recall e viene utilizzata per bilanciare le due metriche, specialmente in dataset sbilanciati:

$$\text{F1-score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \tag{18}$$

L'F1-score è utile perché permette di valutare il modello in modo più equilibrato rispetto alla sola accuratezza, specialmente quando una classe è molto più frequente dell'altra.

- Se $F1 \longrightarrow 1$, il modello è perfetto.
- Se $F1 \longrightarrow 0$, il modello non effettua alcuna previsione corretta.

Matrice di Confusione

La matrice di confusione è una rappresentazione tabellare delle predizioni del modello, che permette di analizzare in dettaglio le prestazioni della classificazione.

L'analisi della matrice di confusione consente di comprendere meglio gli errori del modello e identificare eventuali problemi di sbilanciamento nelle previsioni. Per un problema di classificazione binaria, la matrice di confusione è strutturata come segue nella Tabella 4:

	Predetto Positivo	**Predetto Negativo**
Reale Positivo	TP (True Positives)	FN (False Negatives)
Reale Negativo	FP (False Positives)	TN (True Negatives)

Tabella 4: Rappresentazione delle predizioni corrette ed errate del modello di classificazione.

Curva ROC

La **Receiver Operating Characteristic (ROC)** è una curva che rappresenta la performance di un classificatore binario al variare della soglia di decisione. L'asse x della curva ROC corrisponde al **False Positive Rate (FPR)**, mentre l'asse y rappresenta il **True Positive Rate (TPR)**, definito come:

$$\text{TPR} = \frac{TP}{TP + FN}, \quad \text{FPR} = \frac{FP}{FP + TN} \tag{19}$$

Un modello ideale avrebbe una curva ROC che passa attraverso il punto $(0, 1)$, indicando un **FPR nullo** e un **TPR massimo**, ossia nessun falso positivo e tutti i positivi correttamente identificati.

Curva AUC

L'**Area Under the Curve (AUC)** misura la capacità del modello di distinguere tra le classi. L'AUC assume valori tra 0 e 1, dove:

- $AUC = 1$ indica un classificatore perfetto.
- $AUC = 0.5$ indica un modello casuale.
- $AUC < 0.5$ indica che il modello assegna sistematicamente punteggi più alti alla classe sbagliata; tuttavia, le sue prestazioni possono essere migliorate invertendo le predizioni.

Un elevato valore di AUC suggerisce che il modello è in grado di discriminare efficacemente tra le due classi.

Capitolo 3

Risultati e Discussione

In questa sezione vengono analizzati i risultati ottenuti dall'applicazione di quattro diversi algoritmi di classificazione ai segnali ECG, con l'obiettivo di distinguere tra segnali affetti da **fibrillazione atriale** e **segnali normali**. Il dataset iniziale includeva anche altre tipologie di ritmo cardiaco, tra cui flutter atriale (AFL), ritmi di giunzione (J), segnali rumorosi (Noisy) e altri ritmi (Other Rhythms). Tuttavia, per questa analisi si è scelto di focalizzarsi esclusivamente sulla distinzione tra AF e N, scartando le restanti classi in quanto non pertinenti rispetto agli obiettivi di classificazione binaria definiti.

Gli algoritmi sono stati valutati in termini di accuratezza, sensibilità, specificità e altre metriche rilevanti, come discusso nel capitolo precedente. Tra gli approcci considerati, il Random Forest ha mostrato le prestazioni complessive più soddisfacenti, con una buona capacità di generalizzazione e una robusta discriminazione tra le due classi.

Nei paragrafi successivi verranno presentati e confrontati nel dettaglio i risultati ottenuti da ciascun modello, evidenziandone punti di forza e criticità, al fine di trarre conclusioni sull'efficacia delle tecniche impiegate per la classificazione automatica della fibrillazione atriale.

3.1 Analisi esplorativa dei dati

A seguito del processo di estrazione delle feature, sono state generate due tabelle distinte, una per ciascuno dei dataset introdotti in precedenza. I segmenti sono stati ottenuti sia direttamente dalle registrazioni del primo dataset, sia dagli episodi annotati del secondo dataset, caratterizzato da una durata significativamente maggiore (circa 10 ore per registrazione). Per garantire uniformità tra i dati analizzati, anche gli episodi del secondo dataset sono stati suddivisi in finestre di 10 secondi, analogamente a quanto fatto per il primo dataset.

Ogni riga delle tabelle, esportate in formato *csv*, rappresenta un segmento di segnale ECG ed è accompagnata dalle relative caratteristiche temporali e non lineari calcolate. Queste tabelle costituiscono la base per l'analisi esplorativa, in quanto permettono di osservare e confrontare le metriche potenzialmente discriminanti tra i tracciati affetti da fibrillazione atriale e quelli normali, come illustrato nelle Tabelle 5 e 6.

È importante sottolineare che, nella costruzione dei set di dati utilizzati per l'addestramento e la valutazione dei modelli, è stato **evitato accuratamente qualsiasi sovrapposizione tra pazienti**. In particolare, nessun segmento presente nel test set proviene da pazienti già inclusi nel training set. Questo accorgimento metodologico ha lo scopo di garantire una **valutazione imparziale** delle capacità predittive del modello, evitando che esso possa beneficiare, anche indirettamente, di informazioni già apprese su pazienti noti.

Le colonne presenti sia nel primo che nel secondo dataset sono le seguenti:

- segmentNumber: identificativo numerico univoco del segmento di un segnale;
- label: etichetta associata al segmento, indicante la classe di appartenenza (AF per fibrillazione atriale, N per soggetto normale);
- Heart Rate: frequenza cardiaca media all'interno del segmento, espressa in battiti per minuto (bpm);
- Mean RR: valore medio degli intervalli R-R espresso in millisecondi (ms), rappresenta il tempo medio tra due battiti consecutivi;
- STDRR: deviazione standard degli intervalli R-R, espressa in millisecondi (ms), fornisce una misura della dispersione temporale tra i battiti;
- RMSSD: radice quadrata della media dei quadrati delle differenze successive tra intervalli R-R, espressa anch'essa in millisecondi (ms). È un indicatore comunemente utilizzato per stimare l'attività parasimpatica;
- SD1: misura della dispersione trasversale nel piano di Poincaré, correlata alla variabilità a breve termine della frequenza cardiaca;
- Sample Entropy: entropia campionaria, che quantifica la complessità e l'imprevedibilità della serie temporale;
- Approximate Entropy: entropia approssimata, un'altra misura di regolarità della dinamica del segnale;
- DecelerationCapacity: rappresenta la capacità del cuore di rallentare in risposta a stimoli autonomici, ed è calcolata sulla curva media PRSA.

Tabella 5: Esempi di segmenti del primo dataset con le feature estratte.

segment	label	Heart Rate	Mean RR	STD RR	RMSSD	SD1	SampEn	ApEn	DC
0	N	78.92	0.7617	0.0332	0.0232	0.0164	-0.7828	-0.7828	0.0458
1	N	63.20	0.9662	0.1172	0.1295	0.0916	-0.7256	-0.7256	0.0044
2	N	78.80	0.7736	0.1111	0.1333	0.0943	-0.7688	-0.7688	0.0035
3	AF	66.36	0.9358	0.1790	0.2285	0.1616	-0.6771	-0.6771	0.1246
4	AF	74.31	0.8326	0.1515	0.2162	0.1528	-0.7533	-0.7533	0.0263

Tabella 6: Esempi di segmentazione su episodi del secondo dataset con le feature estratte.

segment	label	Heart Rate	Mean RR	STD RR	RMSSD	SD1	SampEn	ApEn	DC
0	N	81.82	0.7335	0.0119	0.0088	0.0061	-0.7156	-0.7156	-0.0128
1	AF	66.24	0.9524	0.1855	0.1901	0.1341	-0.5179	-0.5179	-0.2296
2	N	74.98	0.8003	0.0090	0.0138	0.0097	-0.7056	-0.7056	0.0060
3	N	76.38	0.7910	0.0579	0.0659	0.0446	-0.7319	-0.7319	-0.0313
4	N	85.23	0.7058	0.0342	0.0591	0.0418	-0.7156	-0.7156	0.0114

3.2 Addestamento dei Modelli di Machine Learning

Per valutare le prestazioni dei modelli di classificazione applicati ai segnali ECG, sono stati condotti esperimenti su entrambi i dataset.

Al fine di analizzare la capacità generalizzativa dei modelli e confrontare la loro robustezza su dati differenti, sono stati effettuati tre esperimenti di addestramento e validazione, utilizzando diversi approcci:

- **Primo esperimento**: il primo dataset è composto da numerose registrazioni ECG di breve durata (circa 9–60 secondi). Su ciascun segnale è stato applicato un processo di **preprocessing**, seguito dalla **segmentazione** in finestre da 10 secondi. Per ogni segmento così ottenuto sono state calcolate le **feature**, generando un insieme numeroso e omogeneo di dati. Successivamente, l'intero set di segmenti è stato suddiviso in 80% per l'addestramento e 20% per il test, al fine di valutare le prestazioni del modello in condizioni ideali, ossia con dati provenienti dallo stesso dominio.

  È stato tuttavia prestato particolare attenzione ad evitare che segmenti appartenenti allo stesso paziente fossero presenti contemporaneamente sia nel training che nel test set, al fine di impedire che il modello apprendesse involontariamente caratteristiche specifiche di un paziente, compromettendo così la generalizzabilità delle valutazioni.

- **Secondo esperimento**: il secondo dataset presenta una struttura completamente diversa, contiene un numero più limitato di registrazioni, ma ciascuna di esse ha

una durata molto estesa (fino a 10 ore). In questo caso, è stato innanzitutto effettuato il pre-processamento e subito dopo il **rilevamento degli episodi annotati** di fibrillazione atriale e ritmo normale. Ogni episodio, di lunghezza variabile da pochi secondi a diverse decine di minuti, è stato a sua volta **segmentato** in finestre fisse di 10 secondi, su cui sono state calcolate le stesse metriche utilizzate nel primo esperimento. L'intero insieme dei segmenti generati a partire dal secondo dataset — pari a 84.056 segmenti totali — è risultato di dimensioni considerevoli e potenzialmente oneroso dal punto di vista computazionale. Per tale motivo, è stato selezionato un sottoinsieme rappresentativo composto da 9.180 segmenti, che è stato successivamente suddiviso in 80% per l'addestramento e 20% per la fase di test, secondo la stessa proporzione adottata nel primo esperimento.

Anche in questo caso è stato evitato che segmenti provenienti dallo stesso paziente comparissero in entrambi i sottoinsiemi, per mantenere la separazione tra soggetti in fase di apprendimento e validazione e garantire una stima più attendibile della capacità del modello di generalizzare a nuovi individui.

Questo approccio ha permesso di contenere i costi computazionali pur mantenendo una sufficiente varietà dei dati, consentendo al tempo stesso di valutare la capacità del modello di apprendere da un dataset caratterizzato da segnali di natura clinica più complessa e variabile.

- **Terzo esperimento**: in questo caso, il modello è stato addestrato utilizzando un sottoinsieme del primo dataset, composto da 5.834 segmenti da 10 secondi ciascuno, ed è stato testato su una parte del secondo dataset, da cui sono stati estratti 1.162 segmenti ottenuti mediante la suddivisione degli episodi annotati in finestre della stessa durata.

  L'utilizzo dell'intero secondo dataset come set di test ha permesso di valutare in modo più completo la **capacità di generalizzazione** del modello su **dati indipendenti** poiché ricavati da un altro dataset rispetto a quelli utilizzati per l'addestramento.

  Questa configurazione è stata adottata per garantire una maggiore coerenza strutturale tra i due insiemi di dati, dal momento che, originariamente, il secondo dataset presentava episodi di durata variabile e significativamente inferiore rispetto ai segmenti del primo. La suddivisione in finestre ha permesso di standardizzare la lunghezza degli input, rendendo il confronto più equo ed efficace.

  Proprio per questo motivo, il test sul secondo dataset risulta particolarmente utile per verificare la robustezza del classificatore in un contesto clinicamente realistico, caratterizzato dalla presenza di episodi parossistici di fibrillazione atriale. Questi eventi, a causa della loro natura intermittente e non persistente, rappresentano una

sfida diagnostica più complessa rispetto ai tracciati patologici continui. La capacità del modello di identificare correttamente tali manifestazioni risulta quindi di particolare interesse clinico, poiché esse sono spesso difficili da rilevare attraverso i metodi tradizionali [16].

3.2.1 Confronto tra Modelli di Classificazione

In ciascuno dei tre esperimenti condotti, sono stati testati quattro diversi algoritmi di classificazione:

- **Random Forest**
- **Support Vector Machine (SVM)**
- **Gradient Boosting Classifier**
- **K-Nearest Neighbors (KNN)**

Le performance dei modelli sono state valutate tramite le **matrici di confusione**, che riportano:

- **TP (True Positives)**: casi di fibrillazione atriale correttamente classificati
- **TN (True Negatives)**: casi normali correttamente classificati
- **FP (False Positives)**: casi normali classificati come casi di fibrillazione atriale
- **FN (False Negatives)**: casi di fibrillazione atriale classificati come normali

Esperimento 1 – Primo dataset (80% train / 20% test)

Tabella 7: Matrice di confusione – Esperimento 1 Test set

Modello	TP	TN	FP	FN	Sens	Spec
Random Forest	81	548	146	23	0.77	0.78
Support Vector Machine (SVM)	70	530	164	34	0.67	0.76
Gradient Boosting Classifier	66	502	192	38	0.63	0.72
K-Nearest Neighbors (KNN)	59	493	201	45	0.56	0.71

La **Random Forest** ha evidenziato le migliori prestazioni, mostrando un ottimo equilibrio tra sensibilità e specificità. Al contrario, il KNN ha registrato un numero maggiore di falsi positivi.

Esperimento 2 – Secondo dataset (80% train / 20% test)

Tabella 8: Matrice di confusione – Esperimento 2 Test set

Modello	TP	TN	FP	FN	Sens	Spec
Random Forest	1025	674	42	95	0.92	0.94
Support Vector Machine (SVM)	845	637	79	275	0.75	0.88
Gradient Boosting Classifier	928	650	66	192	0.82	0.90
K-Nearest Neighbors (KNN)	909	681	65	171	0.84	0.91

La **Random Forest** ha confermato elevate capacità predittive anche in presenza di un numero relativamente limitato di campioni, distinguendosi per l'equilibrio tra sensibilità (0.92) e specificità (0.94). Questo evidenzia l'efficacia del modello nel riconoscere correttamente sia i tracciati affetti da fibrillazione atriale che quelli normali.

Il **Gradient Boosting Classifier** ha mostrato prestazioni comparabili, con una sensibilità pari a 0.82 e una specificità di 0.90. Sebbene leggermente inferiori rispetto alla Random Forest, tali valori indicano una buona capacità del modello di apprendere schemi significativi dai dati.

Il modello **Support Vector Machine** ha invece evidenziato limitazioni più marcate, in particolare sul piano della sensibilità (0.75), suggerendo una maggiore difficoltà nel rilevare correttamente gli episodi di fibrillazione atriale. Anche la specificità, sebbene accettabile (0.88), risulta inferiore rispetto agli altri modelli.

Per ultimo, il **K-Nearest Neighbors** ha ottenuto risultati degni di nota, con una sensibilità pari a 0.84 e una specificità di 0.91. Nonostante queste prestazioni siano competitive, è importante sottolineare che l'esperimento è stato condotto su un campione contenuto. Di conseguenza, l'apparente miglior equilibrio nelle metriche potrebbe non essere confermato in presenza di dataset più ampi e clinicamente eterogenei, come osservato in esperimenti precedenti.

Esperimento 3 – Train su primo dataset, test su secondo dataset

Tabella 9: Matrice di confusione – Esperimento 3 Test set

Modello	TP	TN	FP	FN	Sens	Spec
Random Forest	647	299	127	89	0.88	0.70
Support Vector Machine (SVM)	593	265	161	143	0.80	0.62
Gradient Boosting Classifier	614	275	151	122	0.83	0.64
K-Nearest Neighbors (KNN)	605	276	156	125	0.82	0.63

Nel terzo esperimento, il modello **Random Forest** ha confermato la sua superiorità, registrando le migliori prestazioni tra tutti gli algoritmi considerati. Con un'accuratezza complessiva del **81%**, ha mostrato un buon equilibrio tra sensibilità (0.88) e specificità (0.70), dimostrandosi efficace nella rilevazione dei casi fibrillazione atriale pur mantenendo una buona capacità di identificare correttamente i tracciati normali.

I modelli **Gradient Boosting** e **K-Nearest Neighbors (KNN)** hanno ottenuto risultati leggermente inferiori, con accuratezze rispettivamente pari a **74.87%** e **75.03%**, e sensibilità leggermente più basse (0.83 e 0.82), accompagnate da specificità comprese tra 0.64 e 0.63. Il modello **SVM**, infine, ha mostrato le prestazioni più deboli, con un'accuratezza del **73.6%**, una sensibilità pari a 0.80 e una specificità di 0.62, evidenziando una maggiore difficoltà soprattutto nella corretta classificazione dei segmenti affetti da fibrillazione atriale.

Complessivamente, la **Random Forest** si è confermata il modello più affidabile e robusto, in grado di generalizzare efficacemente su dati provenienti da un dataset distinto rispetto a quello utilizzato in fase di addestramento.

3.2.2 Analisi delle Performance del Modello Random Forest

Dopo l'analisi comparativa tra i diversi modelli di classificazione, il **Random Forest** ha dimostrato le prestazioni più elevate nei tre esperimenti condotti. La sua efficacia può essere ricondotta sia alle caratteristiche strutturali dell'algoritmo sia alle scelte adottate nella fase di **ottimizzazione** e **validazione**.

Un aspetto cruciale della metodologia ha riguardato la suddivisione dei dati in fase di addestramento e test: tale separazione è stata effettuata non solo garantendo il mantenimento della distribuzione bilanciata tra classi, ma soprattutto evitando che segmenti appartenenti allo stesso paziente fossero presenti in entrambe le fasi. Il modello Random Forest è stato successivamente sottoposto a un processo di **ottimizzazione degli iperparametri tramite una ricerca a griglia (Grid Search)** abbinata a una validazione incrociata a cinque fold. La griglia comprendeva diverse combinazioni di parametri chiave, tra cui il numero di alberi nella foresta **(n_estimators)**, la profondità massima degli alberi **(max_depth)**, il numero minimo di campioni richiesto per suddividere un nodo **(min_samples_split)** e il numero minimo di campioni in un nodo foglia **(min_samples_leaf)**. Questo processo ha permesso di individuare la configurazione ottimale del modello, corrispondente a 100 alberi (n_estimators=100), una profondità massima di 20 (max_depth=20), un minimo di 2 campioni per suddividere un nodo (min_samples_split=2) e almeno 4 campioni per ogni nodo foglia (min_samples_leaf=4). Tale configurazione ha garantito il miglior compromesso tra accuratezza e stabilità del modello, come evidenziato dai risultati della validazione incrociata.

L'approccio ensemble del Random Forest, che combina le decisioni di **molteplici alberi** generati su **sottocampioni differenti** del dataset, ha contribuito a migliorare la **generalizzazione** del modello e a ridurre il rischio di **overfitting**. Inoltre, la **selezione casuale** delle feature durante la costruzione degli alberi ha reso il modello meno sensibile alla presenza di variabili meno informative.

```
from sklearn.model_selection import train_test_split,
    GridSearchCV
from sklearn.ensemble import RandomForestClassifier

# Suddivide i dati in training e test set
X_train, X_test, y_train, y_test = train_test_split(
    X_scaled, y, test_size=0.2, stratify=y, random_state=42
)

# Definizione del modello Random Forest
rf_model = RandomForestClassifier(random_state=42, class_weight='
    balanced')

# Griglia degli iperparametri
param_grid = {
    'n_estimators': [50, 100, 200],
    'max_depth': [None, 10, 20],
    'min_samples_split': [2, 5, 10],
    'min_samples_leaf': [1, 2, 4]
}


# Grid Search con Cross Validation (5-fold)
grid_search = GridSearchCV(rf_model, param_grid, cv=5, scoring='
    accuracy')
grid_search.fit(X_train, y_train)
```

Listing 3.1: Addestramento Random Forest con Grid Search Cross Validation.

Attraverso l'approccio descritto, basato sulla suddivisione stratificata dei dati e sull'ottimizzazione degli iperparametri tramite ricerca a griglia con validazione incrociata, siamo riusciti a **massimizzare l'efficacia del modello Random Forest**. Tale configurazione ha permesso di ottenere un modello non solo accurato, ma anche stabile nei diversi scenari sperimentali.

Un ulteriore punto di forza del modello **Random Forest** è la possibilità di analizzare la **rilevanza delle feature** utilizzate nel processo decisionale. L'analisi dell'importanza relativa delle variabili in ingresso è stata effettuata in occasione del **terzo esperimento**,

in quanto rappresentava lo scenario più complesso. Questa scelta ha permesso di valutare l'efficacia delle metriche in un contesto di classificazione più impegnativo, caratterizzato da una maggiore variabilità tra i dati di training e quelli di test. Tuttavia, i risultati ottenuti in termini di rilevanza delle feature si sono rivelati **coerenti anche con quelli derivanti dagli altri due esperimenti**, confermando che alcune metriche giocano un ruolo determinante nel distinguere tra fibrillazione atriale e ritmo normale.

Come mostrato nella Figura 9, la metrica denominata **DC** ha mostrato un'importanza significativa nel processo di classificazione. Questa metrica è derivata direttamente dall'**analisi PRSA (Phase Rectified Signal Averaging)**, e misura la **capacità di risposta del sistema cardiovascolare in corrispondenza di eventi deceleratori**. L'elevata rilevanza della DecelerationCapacity emersa durante l'addestramento del modello suggerisce che essa rappresenta un **indicatore informativo delle alterazioni caratteristiche associate alla fibrillazione atriale**, e risulta particolarmente utile per distinguerla dai tracciati normali. Oltre alla metrica DC, anche altre feature si sono dimostrate altamente informative nel processo di classificazione, in particolare quelle legate alla complessità e alla variabilità del segnale cardiaco.

Tra queste, la **Sample Entropy** e la **Approximate Entropy** hanno ottenuto punteggi elevati in termini di importanza, evidenziando il ruolo delle caratteristiche non lineari del segnale nella discriminazione tra soggetti normali e affetti da fibrillazione atriale. Tali metriche sono generalmente utilizzate per descrivere l'irregolarità e l'imprevedibilità delle variazioni nei segnali fisiologici.

Anche le metriche classiche di variabilità del ritmo cardiaco, come la **deviazione standard degli intervalli RR (STDRR)**, la **RMSSD** e la **SD1**, hanno fornito un contributo significativo.

Infine, parametri più semplici come la **frequenza cardiaca media (Heart Rate)** e il **Mean RR** hanno mostrato un'importanza inferiore, pur mantenendo un ruolo complementare nel supportare il processo decisionale del modello, di seguito ecco un grafico relativo all'importanza delle feature nella Figura 9. Il loro contributo, seppur limitato, può risultare utile per rinforzare le evidenze fornite da metriche più complesse.

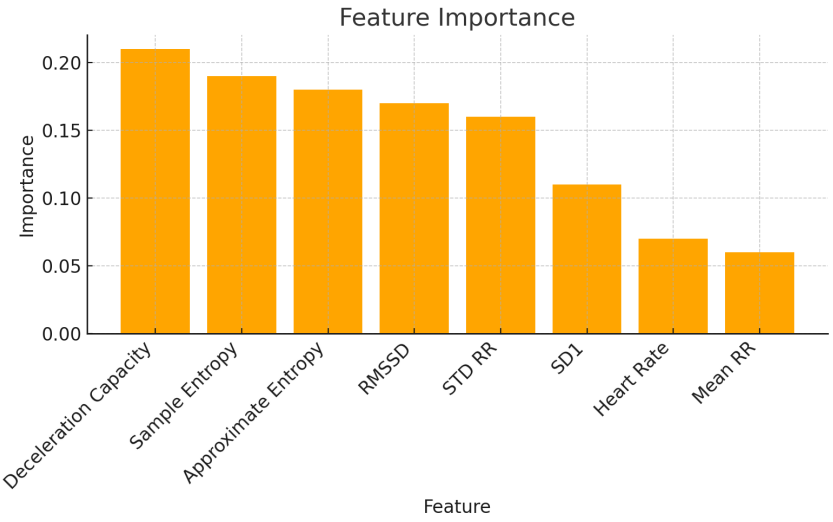


Figura 9: Importanza delle feature secondo il modello Random Forest.

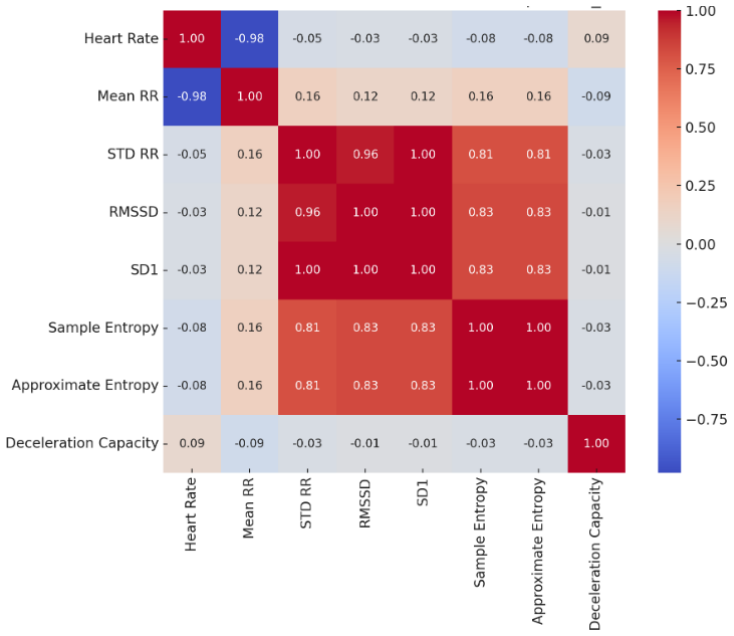


Figura 10: Heatmap delle correlazioni tra le feature.

La Figura 10 mostra la mappa di correlazione tra le variabili utilizzate come feature nel modello di classificazione. Ogni cella della matrice rappresenta il coefficiente di correlazione lineare tra una coppia di variabili, con valori compresi tra -1 e 1. I valori positivi indicano una correlazione diretta, mentre quelli negativi rappresentano una correlazione

inversa. La scala di colori varia dal blu (correlazione negativa) al rosso (correlazione positiva), con il bianco a rappresentare l'assenza di correlazione.

Dal grafico emergono correlazioni particolarmente forti tra le metriche classiche di variabilità cardiaca. In particolare, **STDRR**, **RMSSD** e **SD1** risultano fortemente correlate tra loro (coefficiente > 0.96), suggerendo che descrivono componenti simili della dinamica del segnale ECG. Si conferma inoltre l'elevata anticorrelazione tra **Heart Rate** e **Mean RR** (coefficiente = -0.98), coerente con il fatto che si tratta di grandezze fisiologicamente inverse. Le due metriche legate alla complessità del segnale, ovvero **Sample Entropy** e **Approximate Entropy**, mostrano una correlazione praticamente perfetta tra loro (coefficiente = 1.00), e una correlazione moderata con le metriche classiche della variabilità (coefficiente = 0.83), suggerendo che possono fornire un'informazione parzialmente complementare.

Per ultima, la metrica **DC** mostra un basso livello di correlazione con tutte le altre variabili. Questo aspetto conferma il valore aggiunto di tale feature all'interno del modello: essa fornisce un'informazione complementare, non ridondante rispetto a quella offerta dalle altre metriche. Il suo carattere indipendente giustifica in parte l'elevato punteggio ottenuto nella valutazione dell'importanza delle feature.

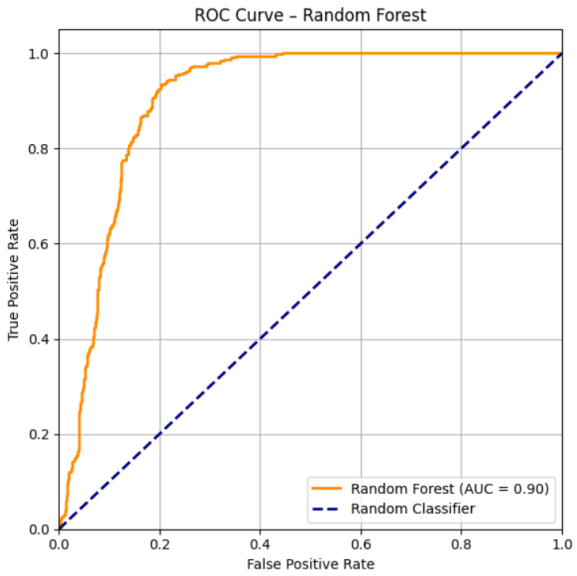


Figura 11: Curva ROC del modello Random Forest (Esperimento 3).

La Figura 11 mostra la curva ROC (Receiver Operating Characteristic) relativa al modello Random Forest applicato al problema di classificazione binaria tra fibrillazione atriale

(AF) e ritmo normale. La curva rappresenta la relazione tra il tasso di veri positivi (True Positive Rate) e il tasso di falsi positivi (False Positive Rate), al variare della soglia di decisione del classificatore.

Nel grafico è evidente l'elevata capacità discriminativa del modello, con un'area sotto la curva (AUC) pari a 0.90. Questo valore indica che il modello è in grado di distinguere correttamente tra i due stati clinici nel 90% dei casi, mantenendo un buon compromesso tra sensibilità e specificità. La presenza di una singola curva ROC riflette correttamente l'impostazione binaria del problema, in cui il modello fornisce una probabilità associata alla classe positiva (AF) e la curva rappresenta le sue performance globali, indipendentemente dalla classe negativa.

L'elevato valore dell'AUC conferma l'efficacia del modello anche su dati non appartenenti al dataset di addestramento, come nel caso dell'Esperimento 3, evidenziando una buona capacità di generalizzazione in contesti clinici realistici.

3.3 Errori e casi critici

Nonostante le buone prestazioni complessive del modello Random Forest, l'analisi della matrice di confusione relativa all'Esperimento 3 evidenzia alcune criticità ricorrenti che meritano attenzione. In particolare, tra i 1.162 segmenti del test set, il modello ha identificato correttamente 647 segmenti affetti da fibrillazione atriale (True Positives) e 299 segmenti normali (True Negatives), ma ha anche commesso 89 falsi negativi (segmenti AF classificati come normali) e 127 falsi positivi (segmenti normali classificati erroneamente come AF).

Il numero non trascurabile di falsi negativi risulta particolarmente critico in ambito clinico, poiché comporta un rischio concreto di mancata rilevazione di episodi patologici. In molti casi, questi segmenti presentano caratteristiche borderline: ad esempio, valori di entropia o metriche di variabilità che rientrano in un intervallo intermedio tra soggetti sani e affetti da AF, rendendo difficile la distinzione.

Parallelamente, i falsi positivi — ovvero i 127 segmenti normali classificati erroneamente come AF — risultano frequentemente associati a una variabilità fisiologica marcata, che, pur essendo non patologica, può presentare tratti di complessità simili a quelli riscontrati nei casi di fibrillazione atriale. In tali circostanze, il modello può essere indotto in errore, confondendo un'attività sinusale irregolare ma fisiologica con un comportamento aritmico.

Una possibile spiegazione a questi errori può essere ricondotta alla natura clinicamente eterogenea dei segnali presenti nel secondo dataset, che include tracciati provenienti da pazienti con profili variabili e condizioni cardiovascolari complesse. Nonostante la segmentazione in finestre di durata uniforme (10 secondi) abbia garantito una coerenza

formale tra i dati di training e di test, le differenze interindividuali e la variabilità del segnale ECG possono comunque influire sulla precisione del modello, specialmente nella distinzione tra ritmi sinusali atipici e veri episodi di fibrillazione atriale

In aggiunta, è emerso un potenziale rischio di overfitting. Sebbene il modello abbia raggiunto ottime performance in fase di addestramento, la riduzione dell'accuratezza nel test set (su dati indipendenti) suggerisce una possibile eccessiva adattabilità alle caratteristiche statistiche del primo dataset. Questo comportamento potrebbe aver compromesso la capacità del modello di generalizzare efficacemente quando esposto a segnali provenienti da contesti clinici differenti, caratterizzati da una maggiore variabilità fisiologica o da disomogeneità introdotte da fattori strumentali.

La validazione incrociata utilizzata nella fase di ottimizzazione degli iperparametri ha contribuito a mitigare il problema, ma non è sufficiente a compensare le differenze strutturali tra i due insiemi di dati. Ciò evidenzia la necessità di introdurre strategie più robuste, quali l'aumento della varietà dei dati di training, l'impiego di tecniche di data augmentation o l'utilizzo di modelli ensemble su dataset provenienti da fonti eterogenee, al fine di migliorare ulteriormente la capacità di generalizzazione del classificatore.

Capitolo 4

Conclusione

Per fornire una visione d'insieme chiara e strutturata del percorso svolto, la Figura 12 riassume graficamente le principali fasi del lavoro, dalla raccolta dei dati alla valutazione finale dei modelli.

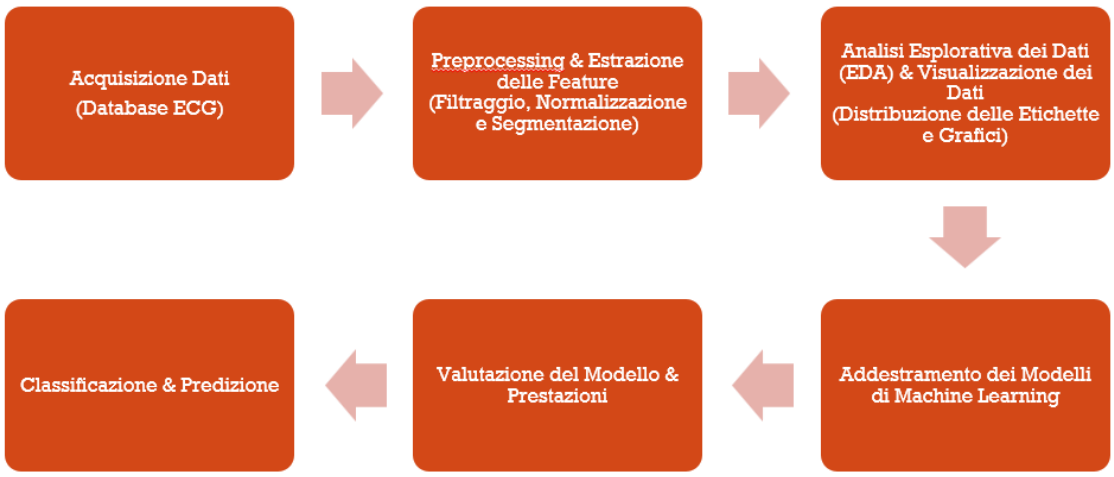


Figura 12: Flusso di lavoro adottato

Questo studio, orientato all'impiego della tecnologia nell'ambito medico, si è focalizzato su una patologia ampiamente diffusa come la fibrillazione atriale. L'applicazione del machine learning per la classificazione automatica di segmenti ECG ha mostrato risultati promettenti, dimostrando come l'integrazione tra analisi dei segnali fisiologici e algoritmi di apprendimento automatico possa costituire un valido supporto per l'individuazione precoce di condizioni cliniche rilevanti.

L'opportunità di approfondire una problematica concreta in ambito sanitario mi ha permesso di rivalutare il potenziale del machine learning in un settore che, fino a oggi,

avevo considerato solo marginalmente.
Questa esperienza ha evidenziato non solo l'impatto concreto che tali tecnologie possono avere nel migliorare i processi diagnostici, ma anche il valore di uno studio interdisciplinare che coniuga informatica, statistica e conoscenza medica.

In prospettiva, modelli come quello proposto possono rappresentare un importante strumento a supporto della ricerca e dell'innovazione nel settore sanitario, contribuendo a rendere le analisi più rapide, oggettive e replicabili.

Un ruolo fondamentale in questo percorso è stato svolto dal mio relatore e dal mio co-relatore, grazie ai quali ho avuto la possibilità di svolgere parte del lavoro all'interno di un laboratorio di ricerca. In questo contesto ho avuto modo di confrontarmi con studenti e ricercatori impegnati nello studio e nell'elaborazione avanzata di segnali biologici, arricchendo così non solo le mie competenze tecniche, ma anche la mia visione sul ruolo della ricerca applicata.

4.1 Sviluppi futuri

Il lavoro svolto rappresenta un'ulteriore conferma verso l'applicazione di tecniche di machine learning all'identificazione automatica della fibrillazione atriale da segnali ECG. Tuttavia, sono numerose le direzioni attraverso cui questo studio potrebbe essere esteso o migliorato in prospettiva futura, sia dal punto di vista metodologico che applicativo.

Estensione a un problema multi-classe

Un naturale sviluppo del progetto consiste nell'ampliamento della classificazione da binaria a multi-classe, includendo anche altre aritmie cardiache (ad esempio flutter atriale, contrazioni ventricolari premature, pause sinusali). Questo richiederebbe una ristrutturazione dell'intero pipeline e una maggiore robustezza dei modelli nell'adattarsi a segnali con caratteristiche molto diverse tra loro.

Uso di modelli di Deep Learning

L'introduzione di architetture basate su deep learning, come reti neurali convoluzionali (CNN) o ricorrenti (LSTM), potrebbe consentire di apprendere rappresentazioni più complesse direttamente dai segnali grezzi, evitando la necessità di estrazione manuale delle feature. Tali approcci sono particolarmente promettenti nell'ambito dell'analisi di segnali fisiologici a causa della loro capacità di modellare dinamiche temporali e schemi locali.

Tecniche di Explainable AI (XAI)

Un aspetto sempre più centrale nella medicina computazionale è la *spiegabilità* del modello. L'integrazione di tecniche di Explainable AI (come SHAP, LIME o saliency maps)

permetterebbe di fornire indicazioni trasparenti su quali feature o porzioni del segnale abbiano influenzato la decisione del modello, favorendo l'accettazione clinica dell'approccio e migliorando la fiducia dell'utente finale.

Validazione clinica e robustezza su nuovi dati

Un ulteriore sviluppo riguarda la validazione del modello su database provenienti da fonti eterogenee, dispositivi diversi o popolazioni clinicamente variegate. Tale fase è cruciale per garantire la generalizzazione del modello e valutarne le prestazioni in contesti reali, lontani dalle condizioni controllate dei dataset pubblici.

Normalizzazione e gestione della lunghezza dei segmenti

Come emerso nel corso del lavoro, la lunghezza dei segmenti analizzati può influenzare significativamente le metriche estratte. Uno sviluppo possibile è l'introduzione di tecniche di normalizzazione temporale o di segmentazione dinamica, che permettano al modello di adattarsi a finestre di durata variabile senza perdere coerenza nei risultati.

Applicazione in tempo reale su dispositivi indossabili

L'integrazione del modello in un contesto embedded, ad esempio all'interno di dispositivi wearable o mobile, è una prospettiva particolarmente interessante. Ciò comporterebbe lo sviluppo di una pipeline leggera e ottimizzata, in grado di effettuare predizioni in tempo reale e con basso consumo computazionale, potenzialmente utile per il monitoraggio continuo dei pazienti.

Le potenzialità di sviluppo di questo lavoro sono molteplici e richiedono un approccio multidisciplinare che coinvolga competenze tecniche, cliniche e metodologiche. Pertanto un possibile sviluppo futuro sarà quello di rafforzare l'integrazione tra intelligenza artificiale e analisi dei segnali biomedicali, contribuendo allo sviluppo di strumenti sempre più precisi, spiegabili e utili nella pratica clinica quotidiana.

4.2 Riassunto

La **fibrillazione atriale** (AF) è l'aritmia cardiaca sostenuta più comune e rappresenta una delle principali cause di ictus e complicanze cardiovascolari gravi. La diagnosi precoce riveste un ruolo cruciale nella prevenzione e gestione di questa patologia.
Il presente lavoro di tesi si propone di **sviluppare algoritmi di Machine Learning per l'identificazione della fibrillazione atriale a partire da serie temporali di variabilità cardiaca**.

Per la sperimentazione sono stati utilizzati **due dataset** pubblici ampiamente riconosciuti dalla comunità scientifica:

- Il PhysioNet/Computing in Cardiology Challenge 2017, contenente registrazioni ECG monoderivazione di breve durata (9–60 secondi), annotate in quattro classi (Normale, Fibrillazione Atriale, Altre Aritmie e Segnali Rumorosi). Da questo dataset sono stati selezionati solo i segmenti etichettati come "N" (Normale) o "AF", successivamente segmentati in finestre di 10 secondi.

- Il MIT-BIH Atrial Fibrillation Database (AFDB), che fornisce registrazioni a lunga durata (fino a 10 ore) con annotazioni dettagliate sugli episodi di fibrillazione atriale. Da questo dataset sono stati estratti segmenti direttamente dagli episodi annotati, affinché ciascun segmento avesse una durata fissa di 10 secondi, come nel caso del primo dataset.

Sulla base di questi dati, sono stati condotti **tre esperimenti principali**:

- Esperimento 1: addestramento e validazione su un ampio dataset bilanciato (PhysioNet Challenge 2017), segmentato in finestre regolari di 10 secondi. La suddivisione tra training e test è stata effettuata assicurando che i segmenti appartenessero a pazienti differenti, così da evitare la presenza di dati correlati tra le due fasi.

- Esperimento 2: valutazione delle prestazioni dei modelli in uno scenario computazionalmente contenuto, ottenuto selezionando un sottoinsieme casuale di segmenti da un dataset esteso. Anche in questo caso, è stata mantenuta la separazione tra i pazienti nelle fasi di addestramento e test, al fine di verificare la robustezza del modello su segnali clinici complessi e realisticamente variabili.

- Esperimento 3: validazione incrociata tra dataset, con addestramento effettuato su segmenti da 10 secondi ottenuti dal dataset PhysioNet Challenge 2017, e test condotto su finestre della stessa durata ricavate da episodi clinici reali estratti dal MIT-BIH Atrial Fibrillation Database. L'obiettivo di questo esperimento è stato quello di valutare la capacità del modello di generalizzare su dati provenienti da una fonte differente, simulando un contesto più vicino all'applicazione clinica reale.

L'obiettivo di questo esperimento è stato quello di valutare la capacità del modello di generalizzare su dati provenienti da una fonte differente, simulando un contesto più vicino all'applicazione clinica reale.

Prima dell'estrazione delle feature, i segnali ECG sono stati sottoposti a una **fase di preprocessamento** finalizzata al miglioramento della qualità del segnale e alla standardizzazione dei dati provenienti da diverse fonti.

In particolare, sono state applicate le seguenti operazioni:

- **Filtraggio passa-banda** (0.5 – 40 Hz): utilizzato per rimuovere le componenti a bassa frequenza (ad esempio il movimento respiratorio) e le alte frequenze (come rumore muscolare o interferenze elettromagnetiche), preservando la banda utile del segnale ECG.
- **Normalizzazione**: poiché i segnali provenienti dai diversi dataset presentano valori di ampiezza eterogenei — dovuti alle differenze nei dispositivi di acquisizione e nelle condizioni di registrazione — è stato applicato un Min-Max Scaling. Questa tecnica ha permesso di riportare ogni traccia ECG entro un intervallo predefinito, preservando la forma d'onda ma eliminando le differenze di scala tra le registrazioni.

Successivamente, è stata eseguita un'operazione fondamentale per la fase di analisi: il **rilevamento dei picchi R**. Questa procedura, implementata tramite un algoritmo basato su derivata e modulo del segnale, ha consentito di individuare i battiti cardiaci in modo accurato anche in presenza di rumore. La corretta identificazione dei picchi R ha permesso di calcolare gli intervalli RR, ovvero la distanza tra due battiti consecutivi, che costituisce la base per tutte le metriche derivate dalla variabilità della frequenza cardiaca (HRV) che seguiranno.

Le feature estratte si suddividono in tre categorie principali, ovvero **feature statistiche classiche** (Heart Rate, Mean RR, STDRR, RMSSD), **feature non lineari** (SD1, Sample Entropy, Approximate Entropy) e **feature derivate dalla tecnica PRSA** (Capacità di Decelerazione (DC))

Queste feature sono state implementate in modo sistematico su tutti i dati, indipendentemente dal dataset di origine. Il loro utilizzo congiunto ha permesso di fornire ai modelli di classificazione una descrizione ricca e multidimensionale del comportamento cardiaco, utile per distinguere in modo affidabile i casi normali da quelli con fibrillazione atriale.

Per la classificazione automatica dei segmenti ECG sono stati testati **quattro algoritmi di machine learning supervisionato**, scelti per la loro diffusione, robustezza e capacità di gestire dataset con feature eterogenee:

- Random Forest
- Support Vector Machine (SVM)
- K-Nearest Neighbors (KNN)
- Gradient Boosting Classifier

L'algoritmo **Random Forest** ha mostrato fin da subito le **performance più elevate** tra tutti i modelli sperimentati, sia in termini di accuratezza che di stabilità tra i diversi esperimenti. Per questa ragione, è stato scelto come modello di riferimento.

L'ottenimento delle prestazioni migliori è stato attribuito con alta probabilità proprio all'utilizzo della procedura di **Grid Search con validazione incrociata**, che ha permesso di identificare la combinazione ottimale degli iperparametri del modello. Questo processo ha assicurato una selezione bilanciata tra accuratezza e capacità di generalizzazione, evitando il rischio di overfitting e adattando il classificatore in modo efficace alla variabilità intrinseca dei dati.

I risultati sperimentali hanno confermato l'efficacia di questo approccio:

- primo esperimento, condotto su un ampio dataset segmentato, il modello ha raggiunto un'accuratezza del 79%, evidenziando buone prestazioni generali, ma una sensibilità più limitata, a causa dell'elevato numero di falsi negativi.
- secondo esperimento, condotto su un sottoinsieme contenuto ma rappresentativo del secondo dataset. In questo scenario, il modello **Random Forest** ha confermato le sue elevate capacità predittive, ottenendo una sensibilità del 92% e una specificità del 94%, a testimonianza della sua efficacia anche con un numero limitato di campioni.
- terzo esperimento: basato su un approccio di validazione incrociata tra due dataset eterogenei, ha consentito di valutare la capacità di generalizzazione del classificatore su segmenti clinici estratti da episodi reali di durata variabile. Il modello Random Forest ha raggiunto un'accuratezza complessiva del 81% e un sensitività pari al 88%, dimostrando un buon equilibrio tra sensibilità e precisione, anche in presenza di dati non visti durante l'addestramento e caratterizzati da maggiore variabilità fisiologica.

L'analisi dell'importanza delle feature ha permesso di identificare quali **metriche abbiano avuto un impatto maggiore nel processo decisionale del modello**. I risultati hanno evidenziato un ruolo centrale per la capacità di decelerazione, risultata la feature più influente nella distinzione tra fibrillazione atriale e ritmo normale. A seguire, si sono distinte la deviazione standard degli intervalli RR (STDRR) e la Sample Entropy, entrambe capaci di descrivere aspetti critici della variabilità e dell'irregolarità del ritmo cardiaco.

I risultati ottenuti nel corso dei tre esperimenti condotti si sono rivelati complessivamente soddisfacenti, confermando l'efficacia dell'approccio proposto per la classificazione automatica della fibrillazione atriale a partire da segnali ECG di breve durata. L'integrazione di feature eterogenee, combinate con l'impiego di un modello robusto come il Random Forest ottimizzato tramite Grid Search, ha permesso di raggiungere buoni livelli di accuratezza, stabilità e capacità di generalizzazione, anche su dati provenienti da fonti differenti.

Alla luce di questi risultati, un possibile sviluppo futuro potrebbe consistere nell'adozione di tecniche basate sul **Deep Learning**, in particolare reti neurali convoluzionali (CNN) o modelli ibridi con Long Short-Term Memory (LSTM), capaci di apprendere automaticamente le rappresentazioni rilevanti direttamente dal segnale grezzo, senza la necessità di un'estrazione manuale delle feature. Tali modelli, se supportati da un'adeguata quantità di dati e risorse computazionali, potrebbero migliorare ulteriormente le performance, in particolare nel riconoscimento di pattern complessi o di episodi transitori di fibrillazione atriale.

Bibliografia

[1] AIAC - Associazione Italiana di Aritmologia e Cardiostimolazione. Fibrillazione atriale (fa), 2020.

[2] Awni Y Hannun, Pranav Rajpurkar, Mohammad Haghpanahi, Geoffrey H Tison, Cardielle Bourn, Mintu P Turakhia, and Andrew Y Ng. Cardiologist-level arrhythmia detection and classification in ambulatory electrocardiograms using a deep neural network. *Nature medicine*, 25(1):65–69, 2019.

[3] Zachi I Attia, Paul A Friedman, Peter A Noseworthy, Francisco Lopez-Jimenez, David J Ladewig, Gaurav Satam, Patricia A Pellikka, Thomas M Munger, Samuel J Asirvatham, Christopher G Scott, et al. Screening for cardiac contractile dysfunction using an artificial intelligence–enabled electrocardiogram. *Nature medicine*, 25(1):70–74, 2019.

[4] Yuan Xiao, Yu Ding, and Yubo Fan. Ecg-transformer: Arrhythmia classification using attention-based neural networks. In *2020 42nd Annual International Conference of the IEEE Engineering in Medicine & Biology Society (EMBC)*, pages 1064–1067. IEEE, 2020.

[5] Gari D. Clifford, Chengyu Liu, Benjamin Moody, Li-wei H. Lehman, Ikaro Silva, Qiao Li, Alistair E. W. Johnson, and Roger G. Mark. Physionet/computing in cardiology challenge 2017: Af classification from a short single lead ecg recording. `https://physionet.org/challenge/2017/`, 2017.

[6] Ary L. Goldberger, George B. Moody, and Roger G. Mark. Mit-bih atrial fibrillation database (afdb). `https://physionet.org/content/afdb/1.0.0/`, 2000. Accessed: 2024-03-21.

[7] Ary L Goldberger, Luis AN Amaral, Leon Glass, Jeffrey M Hausdorff, Plamen Ch Ivanov, Roger G Mark, Joseph E Mietus, George B Moody, Chung-Kang Peng, and H Eugene Stanley. Physiobank, physiotoolkit, and physionet: components of a new research resource for complex physiologic signals. *Circulation*, 101(23):e215–e220, 2000.

[8] Joshua S Richman and J Randall Moorman. Physiological time-series analysis using approximate entropy and sample entropy. *American Journal of Physiology-Heart and Circulatory Physiology*, 278(6):H2039–H2049, 2000.

[9] M. W. Rivolta, T. Stampalija, D. Casati, E. Ferrazzi, A. Bauer, and R. Sassi. A methodological assessment of phase-rectified signal averaging through simulated beat-to-beat interval time series. In *Computing in Cardiology*, volume 41, pages 601–604, 2014.

[10] T. Stampalija, D. Casati, L. Monasta, R. Sassi, M. W. Rivolta, M. L. Muggiasca, A. Bauer, and E. Ferrazzi. Brain sparing effect in growth-restricted fetuses is associated with decreased cardiac acceleration and deceleration capacities: a case-control study. *BJOG: An International Journal of Obstetrics & Gynaecology*, 123:1947–1954, 2016.

[11] T. Stampalija, D. Casati, M. Montico, R. Sassi, M. W. Rivolta, V. Maggi, A. Bauer, and E. Ferrazzi. Parameters influence on acceleration and deceleration capacity based on trans-abdominal ecg in early fetal growth restriction at different gestational age epochs. *European Journal of Obstetrics & Gynecology and Reproductive Biology*, 188:104–112, 2015.

[12] M. W. Rivolta, T. Stampalija, D. Casati, B. S. Richardson, M. G. Ross, M. G. Frasch, A. Bauer, E. Ferrazzi, and R. Sassi. Acceleration and deceleration capacity of fetal heart rate in an in-vivo sheep model. *PLoS ONE*, 9:e104193, 2014.

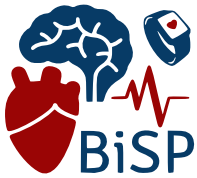
[13] Oliver Faust, Yuki Hagiwara, Tan Jen Hong, and U Rajendra Acharya. Deep learning for healthcare applications based on physiological signals: A review. *Computer methods and programs in biomedicine*, 161:1–13, 2018.

[14] U Rajendra Acharya, Seongwook Oh, Yuki Hagiwara, Jen Hong Tan, and Muhammad Adam. Automated detection of atrial fibrillation using convolutional neural network with long short-term memory and rhythm features. *Computers in biology and medicine*, 100:376–385, 2018.

[15] Siti Nurmaini, Alexander Edo Tondas, Annisa Darmawahyuni, Muhammad Naufal Rachmatullah, and Radiyati Umi Partan. Robust detection of atrial fibrillation from short-term electrocardiogram using convolutional neural networks. *Future Generation Computer Systems*, 113:304–317, 2020.

[16] Hugh Calkins, Karl-Heinz Kuck, Riccardo Cappato, Josep Brugada, A. John Camm, Shih-Ann Chen, Harry J. G. M. Crijns, Ralph J. Damiano, D. Wyn Davies, John P. DiMarco, et al. 2012 hrs/ehra/ecas expert consensus statement on catheter and surgical ablation of atrial fibrillation: Recommendations for patient selection, procedural

techniques, patient management and follow-up, definitions, endpoints, and research trial design. *Heart Rhythm*, 9(4):632–696.e21, 2012.



Progetto sviluppato presso il Biomedical Image and Signal Processing (BiSP) Lab
https://bisp.di.unimi.it
https://di.unimi.it/it/ricerca/risorse-e-luoghi-della-ricerca/laboratori-di-ricerca/bisp-lab-biomedical-image-and-signal-processing-lab